

# MCAD : complétion analytique relative à l'objectif et élagage sûr des requêtes OLAP dans les sessions d'analyse décisionnelle

**Résumé**—Une session d'analyse décisionnelle ne se réduit pas à une succession de requêtes exécutables. MCAD opérationnalise un objectif organisationnel  $O$  sous forme de contraintes et de supports suffisants, puis suit au niveau session l'évidence analytique effectivement acquise. Chaque requête candidate est d'abord représentée par un profil canonique ; le raisonnement distingue admissibilité sémantique, réalisabilité de l'évidence, évidence acquise, calculabilité/contribution et action. Une requête non contributive à l'instant courant n'est donc pas automatiquement dispensable : MCAD ne l'élague avant exécution complète que lorsqu'une condition de sûreté relative à la frontière résiduelle de l'objectif est satisfaite ; sinon, il exécute en *fail-open*. Le cadre vise la complétion analytique relative à  $O$ , non la qualité de la décision humaine.

Nous évaluons séparément la préservation sémantique et le coût système. Les campagnes contrôlées de préservation et de contribution différée n'observent aucune violation de complétion dans leur périmètre gelé et montrent qu'une politique strictement immédiate peut perdre des contributions différées multi-requêtes. Sur SQL Server Direct, une campagne confirmatoire préspecifiée de 300 sessions et 900 bras compare **SAFE\_PRUNING** à **PERMISSIVE\_GATED** sur huit endpoints primaires avec correction de Holm. Six endpoints sont confirmés en faveur de **SAFE\_PRUNING** : requêtes backend incluant les probes, exécutions backend complètes, temps client, CPU SQL Server, octets de réponse et temps jusqu'à complétion analytique. Les lectures et écritures I/O en octets ne sont pas confirmées ; le protocole n'autorise donc aucun claim global indivisible de bénéfice système. Sur XMLA/eMondrian, la réplication secondaire R3-E14, préspecifiée sur 300 sessions et 900 bras, confirme les huit endpoints primaires en faveur de **SAFE\_PRUNING** relativement à **PERMISSIVE\_GATED** ; ce résultat reste endpoint-spécifique et n'autorise ni bénéfice système global, ni équivalence ou homogénéité inter-backend. Ces résultats délimitent un mécanisme de contrôle analytique objectif-relatif, sans claim de valeur décisionnelle humaine ni de supériorité universelle.

**Mots-clés**—Entrepôts de données, OLAP, objectifs analytiques, graphes de connaissances contextuels, profil canonique de requête, évidence de session, complétion analytique, élagage sûr, contrôle pré-backend, reproductibilité.

## I. INTRODUCTION

Les entrepôts de données et les systèmes OLAP structurent l'analyse multidimensionnelle autour de faits, de dimensions, de hiérarchies, de mesures et d'agrégations [1], [2], [3]. Cependant, une session d'analyse décisionnelle ne poursuit pas seulement l'exécution correcte de requêtes : elle vise progressivement à réunir l'évidence nécessaire pour répondre à un objectif explicite. Cet objectif peut mobiliser des KPI, des contraintes métier, des unités, des règles de résumabilité, des fenêtres temporelles et des scénarios. La question pertinente n'est donc pas uniquement de savoir si une requête est valide ou intéressante, mais si son exécution reste nécessaire à la

complétion analytique de l'objectif compte tenu de ce que la session a déjà acquis.

Cette distinction devient critique dans les sessions multi-requêtes. Une requête peut être admissible sans contribuer à l'objectif courant ; inversement, une requête qui ne complète aucune contrainte à l'instant où elle est candidate peut fournir une partie d'un support qui ne deviendra suffisant qu'après une requête ultérieure. Une politique qui confond *non-contribution immédiate* et *dispensabilité sûre* peut ainsi supprimer une information utile à la progression future de la session. Nous partons donc de la séparation suivante :

**NONCONTRIBUTIVE\_NOW**  $\nRightarrow$  **SAFE\_TO\_PRUNE**.

Les travaux voisins apportent des briques essentielles mais poursuivent des finalités distinctes. La personnalisation adapte l'analytique aux préférences et au contexte d'usage [4], [5] ; recommandation et guidage organisent l'exploration [6], [7] ; *interestingness* et contribution caractérisent nouveauté ou utilité analytique [8], [9] ; Intentional Analytics élève l'interaction vers les intentions [10] ; modèles objectifs/KPI et graphes de connaissances structurent enfin les relations entre buts, indicateurs et sémantique [11], [12], [13]. MCAD se positionne à l'intersection de ces familles sans revendiquer la nouveauté de chacune de leurs primitives : sa contribution réside dans leur intégration autour d'un problème précis, celui de déterminer avant exécution complète si une requête candidate peut être écartée sans compromettre la complétion analytique de l'objectif de session.

Nous modélisons l'objectif  $O$  par un graphe objectif-évidence  $G_O$  reliant des contraintes requises à un ou plusieurs supports suffisants, eux-mêmes reliés à des atomes d'évidence analytique. Une contrainte devient calculable dès qu'au moins un de ses supports suffisants est entièrement couvert par l'évidence acquise par la session. L'état de session  $\mathcal{E}_t$  est cumulatif : une exécution complète réussie peut l'enrichir, tandis qu'une requête élaguée ne l'enrichit pas. Cette formulation permet de distinguer contraintes non résolues, partiellement supportées et calculables, ainsi que la frontière résiduelle de l'objectif qui reste à satisfaire.

Chaque requête candidate est ensuite représentée par un *Canonical Query Profile* (CQP), interface canonique indépendante de la syntaxe source utilisée par le raisonneur. Le CQP expose notamment mesures, dimensions, grain, agrégations, filtres, contexte, provenance et correspondances d'évidence. MCAD sépare alors cinq niveaux qui ne doivent pas être confondus : (i) l'admissibilité sémantique du CQP ; (ii) la réalisabilité de l'évidence, éventuellement établie par un probe de non-vacuité ; (iii) l'évidence effectivement acquise après exécution complète ;

(iv) la calculabilité et la contribution relatives à l'état de session ; et (v) l'action opérationnelle. Cette décomposition évite qu'un probe réussi soit traité comme si le résultat analytique avait déjà été acquis.

Le contrôle pré-backend est fondé sur une obligation de sûreté et non sur la seule contribution marginale immédiate. Une requête n'est élaguée que si, sous les hypothèses gelées du modèle et avec un CQP suffisamment fidèle, aucune évidence qu'elle pourrait encore fournir n'intersecte la frontière résiduelle nécessaire à la complétion de  $O$ . Si la canonicalisation, la correspondance d'évidence ou la preuve sont insuffisantes, MCAD exécute en *fail-open*. Cette règle implique aussi que PRUNE ne signifie pas nécessairement "zéro interaction backend" : un probe peut être requis pour établir la réalisabilité et son coût appartient alors au traitement mesuré, même si  $\mathcal{E}_{t+1} = \mathcal{E}_t$  après élagage.

MCAD conserve par ailleurs une séparation stricte entre sémantique et action. Le raisonneur établit ce qui est admissible, réalisable, acquis, calculable et sûr à élaguer ; une politique de déploiement décide ensuite d'exécuter, notifier, avertir, guider, recommander ou bloquer. Les politiques STRICT\_IMMEDIATE, PERMISSIVE\_GATED, UNGATED\_EXECUTE\_ADMISSIBLE et SAFE\_PRUNING utilisées dans nos campagnes sont donc des instruments expérimentaux ou opérationnels distincts du noyau sémantique.

L'article apporte quatre contributions principales :

- un **modèle objectif–évidence de complétion analytique** qui représente explicitement contraintes, supports suffisants alternatifs, évidence cumulative de session et frontière résiduelle de l'objectif, afin de raisonner sur ce qui reste nécessaire plutôt que sur la seule nouveauté d'une requête ;
- un **profil canonique de requête (CQP) et une décomposition épistémique** séparant admissibilité sémantique, réalisabilité, évidence acquise, calculabilité/contribution et action, avec une politique *fail-open* lorsque la fidélité du profil ou la preuve de sûreté est insuffisante ;
- une **règle d'élagage sûr relative à l'objectif et à la session**, qui distingue non-contribution immédiate, contribution différée et dispensabilité sûre, et dont la préservation est évaluée dans des campagnes contrôlées multi-requêtes ;
- une **évaluation système contrôlée et traçable** qui mesure séparément préservation sémantique, requêtes backend incluant les probes, exécutions complètes, temps client, CPU, octets de réponse et temps jusqu'à complétion analytique, sans transformer un résultat partiel en claim global de bénéfice système.

L'évaluation fournit quatre niveaux d'évidence complémentaires. Premièrement, les campagnes contrôlées de préservation et de contribution différée n'observent aucune violation de complétion dans leur périmètre gelé et montrent qu'une politique strictement immédiate peut perdre des contributions différées multi-requêtes. Deuxièmement, une phase d'évaluation end-to-end montre que la réduction du travail backend peut coexister avec un coût temporel supérieur à une exécution non contrôlée, ce qui exclut un claim universel de *break-even*. Troisièmement, la campagne confirmatoire SQL Server Direct préspecifiée

comprend 300 sessions et 900 bras. Pour la comparaison primaire SAFE\_PRUNING versus PERMISSIVE\_GATED, six des huit endpoints primaires sont confirmés après correction de Holm : nombre de requêtes backend incluant les probes, nombre d'exécutions backend complètes, temps client, CPU SQL Server, octets de réponse et temps jusqu'à complétion analytique. Les octets de lecture et d'écriture I/O ne sont pas confirmés. Quatrièmement, la réplication secondaire XMLA/eMondrian R3-E14 comprend elle aussi 300 sessions et 900 bras et confirme, pour le même comparateur primaire, les huit endpoints préspecifiés après correction de Holm. Les résultats SQL Direct et XMLA restent interprétés séparément ; le protocole n'autorise ni composite global ni synthèse cross-backend.

La portée de ces résultats est volontairement bornée. MCAD suppose qu'un objectif et ses supports ont été correctement instanciés en amont ; cette adéquation est une hypothèse de construction et une menace à la validité, non un résultat du mécanisme. De même, la correction et l'efficacité de MCAD ne constituent pas une preuve de correction d'une décision humaine ou organisationnelle. La réplication secondaire XMLA/eMondrian R3-E14 est désormais mesurée et confirme 8/8 endpoints primaires pour SAFE\_PRUNING versus PERMISSIVE\_GATED, sans autoriser de synthèse cross-backend ni de claim global ; l'évaluation de concurrence, de mémoire, de latence de queue et de changement d'échelle end-to-end reste également hors du périmètre confirmé.

La suite de l'article situe d'abord MCAD par rapport aux travaux sur objectifs, représentations canoniques, sessions analytiques, optimisation sémantique, non-vacuité, provenance, admission et élagage physique. Nous présentons ensuite le modèle objectif–évidence, le CQP, les états de session et la condition d'élagage sûr, puis l'architecture qui sépare probes, exécution complète et mise à jour de l'évidence acquise. Enfin, l'évaluation distingue les preuves historiques héritées, les campagnes de préservation et de contribution différée, l'évaluation end-to-end et l'analyse confirmatoire des ressources, avant de discuter explicitement les résultats non confirmés et les frontières encore ouvertes.

## II. TRAVAUX CONNEXES ET FRONTIÈRE DE NOUVEAUTÉ

Le positionnement de MCAD est établi par fonction plutôt que par proximité terminologique. La revue gelée distingue douze familles de travaux (F1–F12) qui couvrent, séparément ou par sous-ensembles, la formalisation d'objectifs, le contexte sémantique, les représentations intermédiaires de requêtes, la personnalisation, les intentions analytiques, les sessions, l'optimisation sémantique, la non-vacuité, la provenance, l'admission de charge, l'élagage physique et la décision. Nous ne formulons aucune revendication de priorité sur ces primitives prises isolément. La frontière de nouveauté porte sur leur articulation dans une chaîne objectif–évidence–session qui permet de décider, avant exécution complète, si une requête peut être élaguée sans compromettre la complétion analytique de l'objectif.

#### A. F1 – Objectifs, KPI et ingénierie orientée buts

Les approches de BI orientée objectifs relient buts, KPI, besoins informationnels et conception multidimensionnelle [11], [14], [12], [15], [16]. Elles motivent directement la formalisation de l'objectif  $O$ , mais leur unité principale est la spécification ou la conception. MCAD se place plus tard dans le cycle : un objectif déjà spécifié est projeté vers des contraintes et des supports suffisants afin de raisonner sur la progression d'une session d'exécution. La qualité métier de cette instanciation reste une hypothèse d'entrée et non un résultat de MCAD.

#### B. F2 et F9 – Contexte sémantique, graphes, résumabilité et provenance

Les graphes de connaissances fournissent une représentation explicite d'entités, de relations et de règles [13] ; les ontologies et vocabulaires multidimensionnels relient sémantique et structures OLAP [17], [18], [19]. La résumabilité borne la correction des agrégations, y compris dans des sessions interactives [20], [21]. La provenance explique quant à elle de quelles données ou transformations dépend un résultat [22], [23]. Des travaux récents relient explicitement graphes de connaissances, contexte et analytique décisionnelle [24], [25]. Ils constituent des voisins directs pour la représentation contextuelle ; la frontière examinée ici porte sur le rôle runtime de l'évidence acquise et de la frontière résiduelle de l'objectif.

MCAD réutilise ces fonctions sans les confondre. Le CKG porte les relations nécessaires au raisonnement objectif-relatif ; la résumabilité contribue à l'admissibilité sémantique ; la provenance peut justifier l'origine d'une évidence. Aucune de ces propriétés ne suffit à établir que l'évidence a effectivement été acquise par la session, qu'elle complète un support de  $O$ , ou qu'une requête est sûre à élaguer.

#### C. F3 – Représentations canoniques et interchange de plans

Les infrastructures de traitement de requêtes disposent déjà de représentations intermédiaires générales. Apache Calcite fournit une algèbre et une architecture extensible de traitement et d'optimisation sur des sources hétérogènes [26] ; Substrait définit une sérialisation inter-langages de plans relationnels destinée à l'échange entre producteurs et consommateurs de plans [27]. Le CQP (*Canonical Query Profile*) de MCAD n'est ni un remplaçant d'optimiseur ni un format universel d'interchange. Il constitue une projection canonique, plus étroite, des propriétés nécessaires au raisonnement objectif-évidence : mesures, dimensions, grain, agrégations, filtres, temporalité, contexte et correspondances d'évidence. La contribution est donc dans le contrat de fidélité requis pour la décision MCAD et dans son usage objectif-relatif, non dans l'idée générale de canonicaliser une requête.

#### D. F4 et F5 – Personnalisation, exploration et Intentional Analytics

La personnalisation adapte vues et requêtes aux préférences de l'utilisateur [4], [5] ; la recommandation et le guidage structurent la continuation d'une exploration [6], [7]. Les travaux sur la contribution d'exploration et l'*interestingness*

évaluent nouveauté, intérêt ou réussite d'une séquence [8], [9]. Intentional Analytics élève enfin l'interaction vers des intentions analytiques de haut niveau [10], [28]. Des prolongements récents étudient la prédiction de cubes multidimensionnels et l'optimisation multi-requête de l'opérateur ANALYZE [29], [30] ; ils renforcent le voisinage sur l'intention et les ensembles de requêtes sans être assimilés à la sémantique de complétion de MCAD.

Ces finalités sont complémentaires mais différentes. MCAD n'infère ni préférence, ni satisfaction, ni intention humaine ; il ne remplace pas non plus une mesure générale d'*interestingness*. Son état sémantique décrit l'évidence déjà acquise pour un objectif explicitement instancié. Une requête peut être intéressante ou recommandable tout en étant dispensable pour cet objectif ; inversement, une requête peu nouvelle peut rester nécessaire à un support encore incomplet.

#### E. F6 – Sessions analytiques et contribution différée

Les systèmes de recommandation de sessions et les travaux sur l'exploration séquentielle exploitent l'historique de navigation pour proposer ou évaluer des requêtes ultérieures [6], [8]. L'optimisation multi-requête de l'opérateur ANALYZE constitue aussi un voisin récent pour l'exploitation coordonnée de plusieurs requêtes facilitatrices [30]. MCAD utilise également une mémoire de session, mais avec une sémantique différente : l'état  $\mathcal{E}_t$  représente l'évidence analytique effectivement acquise et les supports partiellement ou entièrement couverts. Cette distinction rend possible la contribution différée : une requête non contributive immédiatement peut fournir une partie d'un support qui deviendra suffisant après une requête future. Les campagnes NH-R2 exercent explicitement ce cas ; elles ne justifient toutefois aucune généralisation à toutes les formes de sessions ou d'objectifs.

#### F. F7 et F8 – Optimisation sémantique, satisfiabilité et non-vacuité

L'optimisation sémantique de requêtes exploite des contraintes d'intégrité et des connaissances sur les données pour transformer une requête en une forme équivalente potentiellement moins coûteuse ; elle peut notamment permettre élimination de jointures ou tests de requêtes vides [31]. Une synthèse plus récente systématise le rôle des dépendances de données dans l'optimisation de requêtes [32]. Des travaux dédiés détectent aussi des requêtes à résultat vide avant leur exécution complète, par réutilisation d'information sur des résultats vides antérieurs [33].

MCAD partage l'idée qu'une propriété sémantique peut être utile avant exécution, mais le prédicat de décision est différent. Un test de non-vacuité ou un probe établit seulement une forme de réalisabilité de l'évidence. Il ne crédite pas cette évidence dans  $\mathcal{E}_t$  et n'établit pas à lui seul la dispensabilité. L'élagage sûr dépend de la frontière résiduelle de  $O$  et échoue en mode *fail-open* lorsque la preuve est insuffisante.

#### G. F10 et F11 – Admission de charge, ordonnancement et élagage physique

L'admission control et l'ordonnancement de requêtes traitent des interférences, de la capacité et des objectifs de perfor-

mance du système ; WIQ, par exemple, décide quelles classes de requêtes admettre en fonction de mesures de charge et d'interférence [34]. Des travaux de workload management et d'ordonnancement resource-aware traitent aussi explicitement objectifs de service et besoins de ressources [35], [36] ; SafeLoad cible plus spécifiquement l'identification précoce de requêtes susceptibles de surcharger la mémoire [37]. Le *data skipping* réduit les données physiquement lues en exploitant métadonnées, index ou résumés de provenance ; PBDS utilise ainsi des esquisses de provenance pour accélérer des requêtes ultérieures [38].

MCAD se situe à un niveau distinct. Il ne choisit pas une requête parce que le système est chargé et ne saute pas des blocs physiques à l'intérieur d'une requête déjà admise. Il détermine si l'exécution complète de la requête est encore nécessaire à la complétion analytique de l'objectif. Les gains de requêtes backend, d'exécutions complètes ou de ressources observés en R3-D4 sont des conséquences mesurées de cette décision sémantique dans un protocole donné, et non une assimilation de MCAD à une technique d'admission ou de *data skipping*.

#### H. F12 – Systèmes d'aide à la décision et valeur de la décision

La BI&A et les méthodes orientées objectifs servent des processus décisionnels organisationnels [3], [11]. Les méthodes d'optimisation contextuelle abordent explicitement la prise de décision sous incertitude [39]. MCAD traite une question différente : il ne prescrit pas l'action décisionnelle et n'optimise pas directement la décision ; il détermine si l'exécution complète d'une requête reste nécessaire à la complétion analytique d'un objectif formalisé. Cela ne signifie pas qu'une amélioration d'un mécanisme analytique prouve une amélioration de la décision humaine. MCAD évalue la complétion analytique d'un objectif formalisé et le coût système du contrôle correspondant. La correction de la décision humaine, la qualité d'un choix organisationnel, la satisfaction ou la valeur métier finale restent hors du périmètre empirique actuel.

#### I. Synthèse F1–F12 et frontière de nouveauté

Le Tableau I résume la frontière fonctionnelle. Les cellules indiquent le centre de gravité de chaque famille et non l'absence exhaustive d'une capacité dans chaque système cité.

La différence revendiquée par MCAD est donc intégrative et bornée. Le cadre relie (1) un objectif explicitement formalisé, (2) un graphe objectif–évidence et un contexte sémantique typé, (3) un CQP suffisamment fidèle, (4) l'admissibilité sémantique, (5) la réalisabilité éventuellement sondée, (6) l'évidence effectivement acquise, (7) la frontière résiduelle de l'objectif, puis (8) une décision d'élégage sûr ou d'exécution en *fail-open*. Cette chaîne est distincte d'une recommandation, d'un optimiseur relationnel, d'un test de vacuité, d'un admission controller ou d'une technique d'élégage physique pris isolément.

Nous ne comparons donc pas expérimentalement MCAD à Calcite, Substrait, aux systèmes de recommandation ou aux techniques de *data skipping* comme s'il s'agissait de baselines interchangeables. Les baselines expérimentales de R3 sont des politiques internes qui isolent la question causale propre au mécanisme d'élégage. La littérature sert ici à délimiter la

fonction et la nouveauté conceptuelle ; les résultats empiriques de MCAD ne constituent ni une preuve de supériorité externe, ni une revendication de priorité, ni une validation de valeur décisionnelle humaine.

### III. VUE D'ENSEMBLE DE MCAD

À un niveau macroscopique, MCAD est une couche de contrôle analytique *pré-backend* placée entre une requête candidate et son exécution complète. Elle ne remplace ni le moteur OLAP, ni l'optimiseur du SGBD, ni la politique de décision humaine. Elle reçoit un objectif  $O$ , un contexte sémantique typé, l'état d'évidence de la session et une requête candidate ; elle cherche alors à déterminer si l'exécution complète de cette requête reste nécessaire à la *complétion analytique* de  $O$ . Lorsque la preuve de dispensabilité est insuffisante, MCAD exécute en *fail-open*.

#### A. Chaîne conceptuelle objectif–évidence–action

La Figure 1 résume la chaîne post-A8. Une requête  $q$  est d'abord projetée vers un *Canonical Query Profile* (CQP), c'est-à-dire une représentation canonique des propriétés nécessaires au raisonnement : source/fait, grain, mesures, agrégations, unités, filtres, temporalité, contexte et correspondances d'évidence. Le CQP est soumis à l'admissibilité sémantique. Lorsque la décision l'exige, un probe de non-vacuité peut ensuite établir une forme de réalisabilité ; ce probe est comptabilisé comme interaction backend mais ne crédite pas l'évidence analytique dans l'état de session.

Soit  $N_E(q)$  l'ensemble d'évidence que  $q$  pourrait encore fournir sous le profil et les correspondances considérés, et  $U(\mathcal{E}_t)$  la frontière d'évidence encore utile à la complétion de l'objectif au temps  $t$ . Une condition suffisante d'élégage sûr, formalisée plus loin, prend la forme

$$N_E(q) \cap U(\mathcal{E}_t) = \emptyset.$$

Cette condition exprime une propriété de sûreté, pas une simple absence de contribution immédiate. En particulier,

$$\text{NONCONTRIBUTIVE\_NOW} \not\Rightarrow \text{SAFE\_TO\_PRUNE}.$$

Si la condition de sûreté est établie sous les hypothèses gelées, MCAD peut choisir *PRUNE*. Sinon, ou si la fidélité du CQP, le mapping d'évidence ou la réalisabilité restent incertains, la branche sûre est l'exécution complète.

#### B. Objets principaux : objectif, contexte, CQP et évidence de session

L'objectif  $O$  est représenté par un graphe objectif–évidence  $G_O$  qui distingue trois rôles : les contraintes à rendre calculables, les supports suffisants alternatifs de ces contraintes et les atomes d'évidence analytique dont ces supports dépendent. Une contrainte est calculable lorsqu'au moins un de ses supports suffisants est entièrement couvert par l'évidence effectivement acquise. Cette représentation évite de confondre une cellule potentiellement pertinente avec une obligation unique : plusieurs supports alternatifs peuvent conduire à la même calculabilité.

TABLE I  
CARTOGRAPHIE FONCTIONNELLE DES TRAVAUX CONNEXES (F1–F12) ET FRONTIÈRE AVEC MCAD. LES FAMILLES INDIQUENT DES FONCTIONS DOMINANTES, NON DES EXCLUSIONS EXHAUSTIVES.

| Famille | Fonction dominante / exemples                                        | Objet principalement évalué                                 | Frontière avec MCAD                                                                       |
|---------|----------------------------------------------------------------------|-------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| F1      | Objectifs et KPI [11], [12], [16]                                    | Alignement buts–indicateurs–données                         | MCAD part d'un objectif instancié et raisonne sur sa complétion en session.               |
| F2      | Graphes et contexte sémantique [13], [19], [24], [25]                | Représentation de connaissances et relations                | Le CKG est utilisé pour un raisonnement objectif–évidence typé.                           |
| F3      | IR / plans canoniques [26], [27]                                     | Optimisation, portabilité et interchange de plans           | Le CQP est une projection de fidélité destinée au raisonnement MCAD, pas un IR universel. |
| F4      | Personnalisation [4]                                                 | Préférences et adaptation utilisateur                       | MCAD n'infère pas de préférence ni de satisfaction.                                       |
| F5      | Intentions, contribution, interestingness [10], [8], [9], [29], [30] | Intention, intérêt, nouveauté ou contribution d'exploration | MCAD mesure nécessité relative à une frontière d'objectif, non intérêt général.           |
| F6      | Sessions et navigation [6], [8], [30]                                | Continuation et historique de session                       | $\mathcal{E}_t$ porte l'évidence acquise et permet la contribution différée.              |
| F7      | Optimisation sémantique [31], [32]                                   | Réécriture équivalente sous contraintes                     | MCAD décide de l'exécution complète selon une obligation de sûreté objectif-relative.     |
| F8      | Requêtes vides / non-vacuité [33]                                    | Détection précoce d'un résultat vide                        | Un probe MCAD informe la réalisabilité mais ne met pas à jour l'évidence acquise.         |
| F9      | Résumabilité et provenance [21], [22]                                | Correction d'agrégat et origine du résultat                 | Ces propriétés soutiennent admissibilité/justification sans établir la dispensabilité.    |
| F10     | Admission et ordonnancement [34], [35], [36], [37]                   | Charge, concurrence, capacité et performance                | MCAD contrôle une nécessité analytique, pas une admission fondée sur la charge.           |
| F11     | Data skipping / pruning physique [38]                                | Réduction des données lues pendant l'exécution              | MCAD peut supprimer l'exécution complète d'une requête sous condition de sûreté.          |
| F12     | Aide à la décision [3], [11], [39]                                   | Soutien aux processus décisionnels                          | La valeur ou correction de la décision humaine reste hors scope empirique.                |




FIGURE 1. Chaîne conceptuelle post-A8 de MCAD. Le CQP alimente l'admissibilité et, si nécessaire, un probe de réalisabilité. La décision d'élague est relative à la frontière résiduelle de l'objectif et échoue en *fail-open*. Un probe réussi n'est pas assimilé à de l'évidence acquise ; seule une exécution complète réussie peut enrichir l'état de session.

Le graphe de connaissances contextuel (CKG) porte, pour sa part, la sémantique nécessaire à l'interprétation : schéma multidimensionnel, KPI, grains, unités, agrégateurs, relations de slicers, scénarios, fenêtres temporelles et règles métier. Il fournit le référentiel typé qui permet de construire  $G_O$ , de canonicaliser la requête et d'évaluer l'admissibilité. Le CKG n'est cependant pas assimilé à l'état d'évidence de session. Les relations relativement stables du contexte et l'évidence effectivement acquise au cours de la session sont traitées comme des objets distincts.

L'état  $\mathcal{E}_t$  mémorise l'évidence analytique effectivement acquise avant le traitement de la requête candidate. MCAD distingue alors : (i) l'évidence *potentielle* décrite par le CQP et ses correspondances ; (ii) l'évidence *réalisable*, éventuellement établie par un probe ; et (iii) l'évidence *acquise*, issue d'une exécution complète réussie et pouvant faire progresser les supports de  $G_O$ . Cette distinction est centrale pour les sessions multi-requêtes et la contribution différée.

### C. Contrôle pré-backend, probes et mise à jour de l'état

Le contrôle suit quatre étapes opérationnelles. Premièrement, la requête est canonicalisée et soumise à l'admissibilité sémantique sans créditer d'évidence. Deuxièmement, lorsqu'une propriété de non-vacuité ou de présence physique est nécessaire,

MCAD peut lancer un probe ciblé. Troisièmement, le raisonneur confronte l'évidence potentielle/réalisable de la requête à la frontière résiduelle de  $O$  et cherche une preuve de dispensabilité sûre. Quatrièmement, la politique applique l'action autorisée par cette preuve.

Si la requête est élaguée, aucune exécution complète n'a lieu et l'état acquis reste inchangé :

$$\mathcal{E}_{t+1} = \mathcal{E}_t \quad \text{après PRUNE.}$$

Cette égalité n'implique pas un coût backend nul : un probe antérieur peut avoir été exécuté et son coût est attribué à la session. Si la requête n'est pas sûre à élaguer, MCAD exécute en *fail-open* ; une exécution complète réussie peut alors enrichir  $\mathcal{E}_{t+1}$  avec l'évidence réellement retournée et faire évoluer l'état des supports et contraintes.

La séparation entre raisonnement et politique reste explicite. Le noyau établit admissibilité, réalisabilité, évidence acquise, progression de l'objectif et sûreté de l'élague. La couche d'action décide ensuite de PRUNE, d'exécuter, de notifier ou de guider selon le mode de déploiement. Les politiques expérimentales STRICT\_IMMEDIATE, PERMISSIVE\_GATED, UNGATED\_EXECUTE\_ADMISSIBLE et SAFE\_PRUNING ne sont donc pas des définitions concurrentes du noyau sémantique.




FIGURE 2. Fragment simplifié du graphe objectif-évidence. La calculabilité de  $c_1$  peut être obtenue par  $s_1$  ou  $s_2$  ; l'évidence acquise est suivie au niveau session, tandis que le CKG fournit la sémantique permettant d'interpréter chaque atome.

#### D. Fragment illustratif du graphe objectif-évidence et rôle du CKG

La Figure 2 illustre une contrainte  $c_1$  disposant de deux supports suffisants alternatifs. Le support  $s_1$  dépend de deux atomes d'évidence, tandis que  $s_2$  fournit une autre voie de calculabilité. Le CKG annote ces atomes par les informations de grain, mesure, unité, agrégation, filtres et temporalité nécessaires à leur interprétation.

#### E. Portabilité et frontières de construction

Le CQP rend le raisonnement indépendant de la syntaxe source dans la mesure où un extracteur fidèle est disponible. Le prototype dispose de chemins SQL analytique et MDX/XMLA vers cette représentation ; cela établit une portabilité de représentation bornée, et non l'équivalence de tous les backends. La réplication R3-E14 apporte désormais une confirmation metric-specific sur XMLA/eMondrian, mais elle ne transforme pas cette portabilité de représentation en claim d'équivalence ou d'homogénéité inter-backend. DAX et d'autres langages restent des extensions futures du contrat CQP.

Enfin, les expériences utilisent des CKG, objectifs, contraintes, supports et mappings d'évidence préparés à partir des schémas et règles contrôlés du protocole. La construction automatique de ces objets depuis documents, logs ou règles implicites n'est pas évaluée. Les résultats portent donc sur le raisonnement et le contrôle à partir d'un contexte spécifié, non sur l'acquisition automatique de connaissances ni sur la validité métier indépendante de ce contexte.

### IV. FORMALISATION DE MCAD

Cette section fixe le noyau formel post-A8 de MCAD. Le modèle sépare explicitement : (i) le contexte sémantique relativement stable ; (ii) la structure objectif-évidence qui définit ce qu'il faut rendre calculable ; (iii) le profil canonique de la requête candidate ; (iv) la réalisabilité de l'évidence ; (v) l'évidence effectivement acquise dans la session ; et (vi) la décision opérationnelle. Cette séparation évite trois confusions de l'ancien formalisme : utiliser le même symbole pour les arêtes du graphe et l'évidence de session, assimiler la non-vacuité à l'admissibilité sémantique, et déduire une action d'élégage de la seule contribution marginale immédiate.

TABLE II  
PRINCIPALES NOTATIONS POST-A8 DU MODÈLE MCAD.

| Symbole                         | Description                                                    |
|---------------------------------|----------------------------------------------------------------|
| CKG                             | Graphe de connaissances contextuel relativement stable         |
| $V^K, A^K, \tau^K$              | Nœuds, arêtes et typage du CKG                                 |
| $O$                             | Ensemble fini des contraintes de l'objectif analytique actif   |
| $G_O$                           | Graphe objectif-évidence                                       |
| $C_O, S_O, E_O$                 | Contraintes, supports suffisants et atomes d'évidence de $G_O$ |
| $\text{Supp}(c)$                | Supports suffisants alternatifs de la contrainte $c$           |
| $\text{Req}(s)$                 | Atomes d'évidence requis par le support $s$                    |
| $\mathcal{E}_t$                 | Évidence analytique effectivement acquise par la session       |
| $\text{Comp}(c, \mathcal{E}_t)$ | Calculabilité de $c$ à partir de l'évidence acquise            |
| $C_t^{\leq t}(O)$               | Contraintes calculables cumulativement au temps $t$            |
| $U(\mathcal{E}_t)$              | Frontière résiduelle d'évidence encore utile à l'objectif      |
| $P_q / \text{CQP}$              | Profil canonique de la requête candidate $q$                   |
| $N_E(q)$                        | Sur-ensemble sûr de l'évidence potentielle pertinente de $q$   |
| $R_E(q)$                        | Évidence potentielle dont la réalisabilité a été établie       |
| $A_t$                           | Évidence effectivement acquise à l'étape $t$                   |
| $\text{ADM}(P_q)$               | Admissibilité sémantique du CQP, hors non-vacuité              |
| $\phi_t, \Delta\phi_t$          | Progression et gain immédiat de calculabilité                  |
| $N_E(q) \cap U(\mathcal{E}_t)$  | Test suffisant utilisé pour l'élégage sûr                      |

#### A. Contexte sémantique typé et conventions de notation

Nous considérons un entrepôt multidimensionnel comprenant des faits  $F$ , des dimensions  $D$ , des niveaux  $L(D)$ , des mesures  $M$ , des unités, des agrégateurs, des scénarios et des règles temporelles. Le contexte sémantique est représenté par un graphe de connaissances contextuel

$$\text{CKG} = (V^K, A^K, \tau^K),$$

où  $V^K$  est l'ensemble des nœuds,  $A^K$  l'ensemble des arêtes étiquetées et  $\tau^K$  leur typage. La lettre  $A^K$  est volontairement utilisée pour les arêtes : le symbole  $\mathcal{E}_t$  est réservé, dans toute la suite, à l'évidence analytique effectivement acquise par la session.

Le CKG contient les relations nécessaires pour interpréter grains, mesures, KPI, unités, agrégateurs, slicers, scénarios et fenêtres temporelles. Il ne constitue pas à lui seul la mémoire d'exécution de la session. Les informations relativement stables du contexte et l'évidence acquise au fil des requêtes sont donc des objets distincts.

Le Tableau II résume les notations post-A8.

#### B. Objectif, supports suffisants et graphe objectif-évidence

Soit un objectif analytique

$$O = \{c_1, \dots, c_m\}, \quad m \geq 1,$$

où chaque  $c \in O$  est une contrainte dont nous cherchons la *calculabilité*. La satisfaction métier de la contrainte sur des valeurs observées est une étape distincte : MCAD raisonne ici sur la disponibilité de l'évidence nécessaire à son calcul, pas sur la vérité finale de la décision métier.

L'objectif est matérialisé par un graphe objectif-évidence

$$G_O = (V_O, A_O, \tau_O),$$

avec une partition typée

$$V_O = C_O \dot{\cup} S_O \dot{\cup} E_O,$$

où  $C_O$  contient les contraintes,  $S_O$  les supports suffisants et  $E_O$  les atomes d'évidence analytique. Les arêtes sont limitées aux relations

$$A_O \subseteq (C_O \times S_O) \cup (S_O \times E_O).$$

Pour une contrainte  $c$ , nous notons

$$\text{Supp}(c) = \{s \in S_O \mid (c, s) \in A_O\},$$

et, pour un support  $s$ ,

$$\text{Req}(s) = \{e \in E_O \mid (s, e) \in A_O\}.$$

Chaque support est fini et non vide ; une contrainte peut posséder plusieurs supports suffisants alternatifs. Cette structure est une donnée du modèle d'objectif. Sa pertinence métier et sa construction correcte sont des hypothèses d'entrée ; elles ne sont pas inférées automatiquement par le mécanisme MCAD évalué.

Au temps  $t$ , l'évidence acquise par la session est un ensemble

$$\mathcal{E}_t \subseteq E_O.$$

Une contrainte est calculable si et seulement si au moins un support suffisant est entièrement couvert :

$$\text{Comp}(c, \mathcal{E}_t) \iff \exists s \in \text{Supp}(c) : \text{Req}(s) \subseteq \mathcal{E}_t. \quad (1)$$

Par abus de notation, lorsque le support est identifié à son ensemble d'atomes requis, l'Éq. (1) s'écrit simplement

$$\text{Comp}(c, \mathcal{E}_t) \iff \exists s \in \text{Supp}(c) : s \subseteq \mathcal{E}_t.$$

L'ensemble cumulatif des contraintes calculables est

$$C_{\mathcal{E}}^{\leq t}(O) = \{c \in O \mid \text{Comp}(c, \mathcal{E}_t)\}.$$

La calculabilité est monotone tant que l'objectif et ses supports restent gelés et que l'évidence n'est pas retirée :

$$\mathcal{E}_{t-1} \subseteq \mathcal{E}_t \implies C_{\mathcal{E}}^{\leq t-1}(O) \subseteq C_{\mathcal{E}}^{\leq t}(O).$$

### C. États de contrainte et frontière résiduelle de l'objectif

Pour une contrainte  $c$ , nous distinguons trois états sémantiques :

$$\text{state}(c, \mathcal{E}_t) = \begin{cases} \text{COMPUTABLE}, & \text{Comp}(c, \mathcal{E}_t), \\ \text{PARTIALLY\_SUPPORTED}, & \begin{array}{l} \exists s \in \text{Supp}(c) : \\ 0 < |\text{Req}(s) \cap \mathcal{E}_t|, \\ < |\text{Req}(s)| \end{array} \\ \text{UNRESOLVED}, & \text{sinon.} \end{cases}$$

Une contrainte calculable devient opérationnellement *satisfaite-inactive* pour le problème de complétion ; les autres restent *actives-requises*. Nous posons

$$C_t^{\text{act}} = O \setminus C_{\mathcal{E}}^{\leq t}(O).$$

La *frontière résiduelle d'évidence* est l'ensemble conservateur de tous les atomes encore manquants dans au moins un support d'une contrainte active :

$$U(\mathcal{E}_t) = \bigcup_{c \in C_t^{\text{act}}} \bigcup_{s \in \text{Supp}(c)} (\text{Req}(s) \setminus \mathcal{E}_t). \quad (2)$$

Cette union est volontairement conservatrice : lorsque plusieurs supports sont alternatifs, elle conserve les atomes manquants de chacun d'eux. Elle évite donc d'élaguer une requête simplement parce qu'elle ne complète pas immédiatement le support actuellement le plus avancé.

### D. Canonical Query Profile et fidélité de l'abstraction

Une requête candidate  $q$  écrite dans un langage analytique  $L$  est projetée vers un *Canonical Query Profile*

$$P_q = \text{CQP}_L(q) = (f_q, g_q, M_q, \alpha_q, u_q, S_q, w_q, \Gamma_q, \eta_q),$$

où  $f_q$  décrit la source ou le fait,  $g_q$  le grain,  $M_q$  les mesures/KPI,  $\alpha_q$  les agrégations,  $u_q$  les unités,  $S_q$  les slicers normalisés,  $w_q$  la composante temporelle,  $\Gamma_q$  les correspondances vers les atomes d'évidence et  $\eta_q$  les métadonnées de fidélité/provenance de l'extraction.

Le CQP n'est pas un plan d'exécution physique ni un format universel d'interchange. Il expose seulement les propriétés nécessaires au raisonnement MCAD. L'indépendance vis-à-vis de la syntaxe est donc conditionnelle : elle vaut pour les langages disposant d'un extracteur suffisamment fidèle vers ce contrat.

L'évidence *potentielle* attribuée à la requête est

$$N_E(q) = \{e \in E_O \mid \Gamma_q(e) = 1\}.$$

Pour être utilisé dans une preuve d'élagage,  $N_E(q)$  doit être un sur-ensemble sûr de toute évidence pertinente que l'exécution complète de  $q$  pourrait acquérir relativement à l'objectif courant. Si cette propriété de fidélité ne peut pas être établie, l'élagage n'est pas autorisé et le contrôle passe en *fail-open*.

### E. Admissibilité sémantique séparée de la non-vacuité

L'admissibilité sémantique du CQP est définie par

$$\begin{aligned} \text{ADM}(P_q) \iff & \text{grain\_ok}(P_q) \wedge \text{agg\_ok}(P_q) \wedge \text{unit\_ok}(P_q) \\ & \wedge \text{slc\_ok}(P_q) \wedge \text{time\_ok}(P_q) \wedge \text{map\_ok}(P_q). \end{aligned} \quad (3)$$

Aucun prédicat de non-vacuité n'apparaît dans l'Éq. (3). Les clauses portent respectivement sur le grain et la résumabilité, les agrégateurs, les unités, les combinaisons de slicers, la cohérence temporelle et la validité structurelle des correspondances d'évidence.

La non-vacuité et la présence physique relèvent d'un second niveau. Un probe optionnel peut produire une information de réalisabilité

$$R_E(q) \subseteq N_E(q).$$

Le probe peut confirmer que certains atomes potentiels sont physiquement réalisables, ou au contraire réduire l'ensemble considéré lorsque cette réduction est prouvée sûre. Il ne transforme toutefois pas ces atomes en évidence acquise :

$$\mathcal{E}_t \text{ reste inchangé après le probe seul.}$$

Cette séparation est normative pour le reste du formalisme.

### F. Évidence acquise et transition de session

Soit  $q_t$  la requête candidate à l'étape  $t$ . Nous notons  $A_t \subseteq E_O$  l'évidence effectivement acquise à cette étape. Une exécution complète réussie peut produire

$$A_t \subseteq N_E(q_t),$$

et, lorsqu'un ensemble de réalisabilité  $R_E(q_t)$  a été établi de façon sûre,

$$A_t \subseteq R_E(q_t) \subseteq N_E(q_t).$$

La mise à jour normative de la session est

$$\mathcal{E}_t = \mathcal{E}_{t-1} \cup A_t. \quad (4)$$

Un probe sans exécution complète vérifie  $A_t = \emptyset$ . De même, si la requête est élaguée,

$$\text{PRUNE} \implies A_t = \emptyset \implies \mathcal{E}_t = \mathcal{E}_{t-1}. \quad (5)$$

L'Éq. (5) ne signifie pas que le coût backend est nul : un probe peut avoir été exécuté avant la décision d'élagage et son coût reste attribuable à la session.

### G. Contribution immédiate, contribution différée et progression

Nous conservons un indicateur de progression binaire

$$\phi_t(O) = \frac{|C_{\mathcal{E}}^{\leq t}(O)|}{|O|}, \quad \Delta\phi_t = \phi_t(O) - \phi_{t-1}(O).$$

Cet indicateur décrit la progression de calculabilité ; il ne définit pas, à lui seul, l'action. Une requête peut acquérir une partie d'un support sans rendre immédiatement une nouvelle contrainte calculable. Dans ce cas,  $\Delta\phi_t = 0$  alors que l'évidence acquise peut être nécessaire à une contribution différée ultérieure.

Nous distinguons donc :

$$\text{NONCONTRIBUTIVE\_NOW} \not\equiv \text{SAFE\_TO\_PRUNE}.$$

La contribution différée correspond précisément au cas où  $N_E(q_t)$  intersecte la frontière résiduelle, sans compléter encore un support suffisant. L'expérience NH-R2 exerce ce phénomène dans un périmètre contrôlé ; le formalisme n'en déduit pas une généralisation à toute session analytique imaginable.

### H. Condition suffisante d'élagage sûr

Nous considérons une phase pendant laquelle les hypothèses suivantes sont gelées : l'objectif  $O$ , le graphe  $G_O$ , les supports suffisants et les règles contextuelles ne changent pas ; le CQP est fidèle ou traité en *fail-open* ;  $N_E(q)$  sur-approxime toute évidence pertinente que  $q$  pourrait acquérir ; et l'exécution de  $q$  n'a pas d'effet caché sur la définition de l'objectif ou des supports.

**Proposition 1.** *Sous ces hypothèses, si*

$$N_E(q) \cap U(\mathcal{E}_t) = \emptyset, \quad (6)$$

*alors l'exécution complète de  $q$  ne peut ni compléter ni faire progresser un support encore actif relativement à l'objectif  $O$ . L'élagage de  $q$  préserve donc l'ensemble des contraintes calculables et ne supprime aucune évidence encore nécessaire à un support actif.*

### Algorithm 1 Contrôle objectif-relatif avec élagage sûr

---

**Require:** Requête  $q$ , objectif  $O$ , CKG, évidence acquise  $\mathcal{E}_t$   
**Ensure:** REJECT\_SEMANTIC, PRUNE ou EXECUTE

- 1: Construire  $P_q = \text{CQP}_L(q)$
- 2: **if** la fidélité de  $P_q$  ou de  $N_E(q)$  n'est pas établie **then**
- 3:   **return** EXECUTE {*fail-open*}
- 4: **end if**
- 5: **if** ADM( $P_q$ ) = false **then**
- 6:   **return** REJECT\_SEMANTIC
- 7: **end if**
- 8: Effectuer un probe seulement s'il est requis par le contrôle de réalisabilité
- 9: Ne pas modifier  $\mathcal{E}_t$  à partir du probe seul
- 10: **if**  $N_E(q) \cap U(\mathcal{E}_t) = \emptyset$  **then**
- 11:   **return** PRUNE
- 12: **end if**
- 13: **return** EXECUTE {*fail-open*}

---

*Justification.:* Par définition de  $U(\mathcal{E}_t)$ , tout atome manquant d'un support d'une contrainte active appartient à cette frontière. L'Éq. (6) implique qu'aucun atome que  $q$  pourrait acquérir n'est un de ces atomes manquants. Toute évidence acquise par  $q$  est donc soit déjà présente dans  $\mathcal{E}_t$ , soit extérieure aux besoins résiduels de  $O$ . Aucun support actif ne peut ainsi gagner un élément manquant par l'exécution de  $q$ .

La condition de la Proposition 1 est suffisante et conservatrice ; elle n'est pas présentée comme une caractérisation nécessaire de toute dispensabilité possible. Surtout, son échec n'autorise pas l'élagage : il signifie seulement que la sûreté n'est pas établie par ce test.

### I. Politique de contrôle sûre et fail-open

Le noyau distingue trois sorties de contrôle : rejet sémantique, élagage sûr et exécution. Une version abstraite est donnée par l'Algorithme 1.

Une politique de déploiement peut traduire ces sorties en notification, avertissement, recommandation ou blocage, mais cette couche d'action ne change pas la sémantique de la preuve. Les politiques expérimentales STRICT\_IMMEDIATE, PERMISSIVE\_GATED, UNGATED\_EXECUTE\_ADMISSIBLE et SAFE\_PRUNING sont utilisées pour isoler des mécanismes différents ; elles ne doivent pas être confondues avec des définitions concurrentes de l'objectif.

### J. Temps jusqu'à complétion analytique

Le temps jusqu'à complétion analytique est défini relativement au premier instant où toutes les contraintes de l'objectif deviennent calculables :

$$t_O^* = \inf\{t \mid C_{\mathcal{E}}^{\leq t}(O) = O\}.$$

Dans les campagnes end-to-end, le temps mesuré jusqu'à cette complétion inclut les coûts attribuables à la session : contrôle/gate, probes, exécutions backend complètes et attente associée. Les coûts de démarrage ou restauration de l'environnement, de warm-up global et de décision humaine sont exclus



lorsqu'ils ne sont pas attribuables à la session mesurée. Cette métrique évalue la complétion analytique du protocole, non la qualité de la décision humaine.

#### K. Portabilité bornée du CQP

Le raisonneur dépend du CQP et des relations objectif-évidence, non de la syntaxe source. Le prototype matérialise des chemins SQL analytique et MDX/XMLA vers cette représentation. Cette observation établit une portabilité de représentation bornée à ces extracteurs et aux cas exercés ; elle ne prouve ni l'équivalence de tous les backends ni la validité d'un extracteur pour DAX ou pour tout langage futur. DAX reste une extension à évaluer.

Enfin, le formalisme suppose que le CKG,  $G_O$ , les supports et les mappings d'évidence ont été préparés correctement. La construction automatique de ces objets, l'accord entre experts sur leur contenu et la valeur décisionnelle humaine qui en découle restent hors du périmètre empirique actuel.

### V. ARCHITECTURE DU PROTOTYPE ET FLUX DE TRAVAIL

L'architecture post-A8 traduit directement le contrat formel de la Section IV en un contrôle pré-backend instrumenté. Elle sépare quatre catégories d'état qui ne doivent pas être confondues : (i) les ressources préparées relativement stables, notamment le CKG et le graphe objectif-évidence  $G_O$  ; (ii) le profil canonique et les propriétés déduites de la requête candidate ; (iii) la réalisabilité éventuellement établie par un probe ; et (iv) l'évidence effectivement acquise après une exécution complète réussie. La politique d'action est injectée après le raisonnement afin que les baselines expérimentales ne redéfinissent pas le noyau sémantique.

#### A. Ressources préparées : CKG, objectif et état de session

Le prototype reçoit un CKG typé, un objectif  $O$ , son graphe objectif-évidence  $G_O$ , les supports suffisants et les mappings vers les atomes d'évidence. Ces objets sont chargés comme ressources du scénario ou du déploiement ; MCAD ne prétend pas les découvrir automatiquement à partir de documents, de journaux ou de règles implicites. Le CKG porte le catalogue et la sémantique relativement stables, tandis que  $\mathcal{E}_{t-1}$  porte exclusivement l'évidence acquise avant la requête courante.

Cette séparation est matérialisée dans le chemin de contrôle : la frontière résiduelle  $U(\mathcal{E}_{t-1})$  est recalculée à partir de l'objectif et de l'évidence de session, sans ajouter d'information simplement parce qu'un support est décrit dans le CKG ou dans  $G_O$ .

#### B. Adaptateurs de requête, CQP et gate de fidélité

Une requête candidate  $q_t$  arrive par un adaptateur de langage. Les chemins exercés par le prototype comprennent SQL analytique et MDX/XMLA ; l'adaptateur projette la syntaxe source vers un *Canonical Query Profile*  $P_{q_t}$ . Le CQP expose les propriétés nécessaires au raisonnement – fait/source, grain, mesures, agrégations, unités, slicers, temporalité et correspondances d'évidence – ainsi que les métadonnées permettant d'évaluer la fidélité de l'extraction.

Le premier contrôle est un gate de fidélité. Si l'adaptateur ne peut pas établir une représentation suffisamment sûre de l'évidence potentielle  $N_E(q_t)$ , MCAD n'autorise pas l'élagage et transmet la requête vers la branche *fail-open*. Cette règle est volontairement asymétrique : une incertitude de canonicalisation peut réduire les opportunités d'élagage, mais ne doit pas créer un faux PRUNE.

#### C. Admissibilité sémantique et probe optionnel de réalisabilité

Lorsque le CQP est suffisamment fidèle, le raisonneur évalue  $ADM(P_{q_t})$ . Cette étape couvre grain/résumabilité, agrégation, unité, slicers, temporalité et validité structurelle des mappings d'évidence. La non-vacuité n'est pas une clause d'admissibilité.

Si une propriété de présence physique est requise pour le contrôle, un composant de probe peut effectuer une interaction backend ciblée et produire une information  $R_E(q_t) \subseteq N_E(q_t)$ . Le probe est explicitement séparé de l'exécution complète : il peut établir la réalisabilité, mais il ne produit pas  $A_t$  et ne modifie pas  $\mathcal{E}_{t-1}$ . Son coût est néanmoins enregistré comme interaction backend attribuable à la session.

#### D. Moteur de frontière résiduelle et preuve de safe pruning

Le moteur de contrôle confronte l'évidence potentielle sûre  $N_E(q_t)$  à la frontière résiduelle  $U(\mathcal{E}_{t-1})$ . Sous les hypothèses de fidélité gelées, la politique *SAFE\_PRUNING* peut retourner PRUNE lorsque

$$N_E(q_t) \cap U(\mathcal{E}_{t-1}) = \emptyset.$$

Le prototype traite l'échec de cette condition comme une absence de preuve, pas comme une preuve inverse : si l'intersection est non vide, ou si le mapping/fidélité est incertain, la requête suit la branche EXECUTE. Ainsi, la chaîne opérationnelle respecte

$$\text{NONCONTRIBUTIVE\_NOW} \not\Rightarrow \text{SAFE\_TO\_PRUNE}.$$

Le point d'injection de politique permet également d'exécuter les comparateurs internes sans modifier le raisonneur. *PERMISSIVE\_GATED* constitue le comparateur causal primaire de la campagne confirmatoire SQL Direct ; *UNGATED\_EXECUTE\_ADMISSIBLE* sert de comparateur pratique secondaire de *break-even* ; *STRICT\_IMMEDIATE* reste un baseline sémantique/historique utile pour exposer la perte de contribution différée. Ces politiques ne sont pas des systèmes externes concurrents.

#### E. Exécution backend et commit de l'évidence acquise

Si l'action est PRUNE, aucune exécution complète n'est envoyée au backend et l'état acquis reste inchangé. Si l'action est EXECUTE, le composant d'exécution transmet la requête originale au backend sélectionné, attend la réponse complète et collecte les compteurs attribuables à la session. Une exécution complète réussie peut alors produire l'ensemble  $A_t$  d'évidence effectivement acquise et appliquer

$$\mathcal{E}_t = \mathcal{E}_{t-1} \cup A_t.$$




FIGURE 3. Architecture pré-backend post-A8. Les ressources objectif/contexte et l'état d'évidence de session alimentent le raisonneur ; le CQP est contrôlé pour sa fidélité et son admissibilité ; un probe de réalisabilité est optionnel et ne crédite jamais l'évidence acquise ; la preuve de sûreté décide ensuite entre PRUNE et exécution *fail-open*. Seule une exécution complète réussie peut produire  $A_t$  et mettre à jour  $\mathcal{E}_t$ .

L'architecture interdit donc deux raccourcis : un probe réussi n'est jamais committé comme résultat analytique, et une requête élaguée ne met jamais à jour l'évidence. L'accumulateur de session peut assembler des contributions réparties sur plusieurs requêtes ; ce comportement de contribution différée a été exercé dans la campagne contrôlée NH-R2, sans prétendre couvrir toutes les formes possibles de sessions analytiques.

#### F. Traçabilité, compteurs et temps jusqu'à l'objectif

Chaque traitement produit une trace structurée reliant le CQP, les clauses d'admissibilité, les éventuels probes, la frontière résiduelle, l'action de politique, les interactions backend et la mise à jour d'évidence. Les campagnes end-to-end instrumentent séparément le nombre de requêtes backend incluant les probes, le nombre d'exécutions backend complètes, le temps client, les octets de réponse et, lorsque le backend le permet, les compteurs CPU et I/O.

Le temps jusqu'à complétion analytique est calculé à partir de la même trace de session et inclut les coûts de gate, probes, exécutions complètes et attente attribuables à la session. Il n'inclut pas par construction la qualité de la décision humaine et ne transforme pas une réduction d'un compteur intermédiaire en claim global de bénéfice système.

#### G. Couverture du prototype et frontières empiriques

Le Tableau III relie les composants du modèle post-A8 aux chemins effectivement exercés. Il distingue soigneusement implémentation, preuve de fonctionnement et confirmation expérimentale.

Le chemin SQL Server Direct dispose d'une campagne confirmatoire R3-D pour la comparaison primaire *SAFE\_PRUNING* versus *PERMISSIVE\_GATED*. Le chemin XMLA/eMondrian dispose désormais d'une réplique secondaire R3-E14 mesurée sur 300 sessions et 900 bras ; les 8 endpoints primaires de la même comparaison sont confirmés endpoint par endpoint. Cette confirmation reste distincte de R3-D et n'autorise ni équivalence backend, ni synthèse cross-backend, ni bénéfice système global.

#### H. Workflow de bout en bout

Le workflow opérationnel post-A8 est le suivant :

- 1) charger l'objectif  $O$ ,  $G_O$ , le CKG et l'évidence acquise  $\mathcal{E}_{t-1}$  ;

- 2) recevoir  $q_t$ , construire le CQP  $P_{q_t}$  et vérifier la fidélité de l'abstraction ;
- 3) évaluer  $\text{ADM}(P_{q_t})$  sans créditer d'évidence ;
- 4) si nécessaire, exécuter un probe de réalisabilité, enregistrer son coût et laisser  $\mathcal{E}_{t-1}$  inchangé ;
- 5) calculer  $N_E(q_t)$ , la frontière  $U(\mathcal{E}_{t-1})$  et appliquer la politique choisie ;
- 6) si la sûreté est prouvée sous *SAFE\_PRUNING*, retourner PRUNE ; sinon exécuter en *fail-open* selon le protocole ;
- 7) après une exécution complète réussie, dériver  $A_t$  et mettre à jour  $\mathcal{E}_t = \mathcal{E}_{t-1} \cup A_t$  ; et
- 8) produire la trace explicative et les compteurs de session, puis réévaluer la progression vers la complétion de  $O$ .

Cette architecture maintient ainsi une séparation inspectable entre sémantique, réalisabilité, acquisition d'évidence, politique d'action et effet physique. Elle permet d'évaluer la préservation de la complétion séparément des coûts système, ce qui est nécessaire pour interpréter correctement les campagnes contrôlées et confirmatoires.

## VI. ÉVALUATION EXPÉRIMENTALE

L'évaluation post-A8 est organisée comme une *échelle d'évidence* plutôt que comme une collection de RQ historiques placées au même niveau probatoire. Les campagnes n'ont pas toutes la même fonction : les traces historiques établissent la réalité du prototype et sa diversité de chemins ; NH-R2 cible la préservation sémantique et la contribution différée multi-requêtes ; R3-C teste le comportement de bout en bout face à une exécution admissible non filtrée ; R3-D constitue la campagne confirmatoire SQL Server Direct pour les coûts système et le temps jusqu'à complétion analytique ; R3-E14 constitue la réplique secondaire XMLA/eMondrian, mesurée sur 300 sessions et 900 bras, avec 8/8 endpoints primaires confirmés.

#### A. Questions d'évaluation et hiérarchie probatoire

Nous formulons cinq questions correspondant au mécanisme post-A8 :

- **EQ1 – Préservation de complétion** : une politique d'élagage sûr préserve-t-elle la complétion analytique de l'objectif dans les scénarios contrôlés où ses hypothèses sont gelées ?

TABLE III  
COUVERTURE POST-A8 DU CONTRAT FORMEL PAR LE PROTOTYPE ET FRONTIÈRE DES PREUVES EMPIRIQUES.

| Composant                     | Rôle normatif                                                            | Réalisation / chemin exercé                                                                                                          | Frontière de revendication                                                                                                                       |
|-------------------------------|--------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| CKG + $G_O$ préparés          | Fournir contexte, contraintes, supports et mappings d'évidence           | Ressources de scénario explicitement chargées par les campagnes contrôlées                                                           | Construction automatique et validité métier indépendante non évaluées                                                                            |
| CQP                           | Abstraction canonique nécessaire au raisonnement                         | Adaptateurs SQL analytique et MDX/XMLA vers des propriétés normalisées                                                               | Portabilité bornée aux extracteurs fidèles ; DAX non validé                                                                                      |
| ADM( $P_q$ )                  | Vérifier l'admissibilité sémantique hors non-vacuité                     | Clauses de grain, agrégation, unité, slicers, temps et mapping exposées dans les traces                                              | Un probe n'est pas une clause d'ADM                                                                                                              |
| Probe / $R_E(q)$              | Établir une réalisabilité lorsque requise                                | Interaction backend ciblée instrumentée sur les chemins où le protocole l'exige                                                      | Coût compté ; aucune mise à jour de $\mathcal{E}_t$ par le probe seul                                                                            |
| $U(\mathcal{E}_t)$ + gate sûr | Déterminer si l'évidence potentielle peut encore servir un support actif | Politique SAFE_PRUNING et condition suffisante conservatrice                                                                         | Échec de la preuve $\neq$ autorisation d'élaguer ; <i>fail-open</i>                                                                              |
| Injection de politique        | Isoler le mécanisme sans redéfinir la sémantique                         | STRICT_IMMEDIATE, PERMISSIVE_GATED, UNGATED_EXECUTE_ADMISSIBLE, SAFE_PRUNING                                                         | Baselines internes, pas équivalents des systèmes externes de la littérature                                                                      |
| Exécution complète            | Produire un résultat analytique et éventuellement $A_t$                  | SQL Server Direct mesuré en R3-D ; XMLA/eMondrian mesuré en R3-E14                                                                   | R3-D confirme 6/8 endpoints primaires et R3-E14 en confirme 8/8, séparément ; aucune équivalence backend ni synthèse cross-backend n'est établie |
| Accumulateur de session       | Mettre à jour $\mathcal{E}_t$ après exécution complète réussie           | Assemblage multi-requêtes et contribution différée exercés en NH-R2                                                                  | Pas de généralisation à toutes les formes de session/objectifs                                                                                   |
| Traçabilité / compteurs       | Relier décision, effet physique et coût de session                       | Receipts de décision, probes, requêtes backend, exécutions complètes, temps, octets et compteurs backend disponibles selon le chemin | Les endpoints sont interprétés séparément ; pas de bénéfice système global indivisible                                                           |

- **EQ2 – Contribution différée** : une politique strictement immédiate peut-elle perdre une contribution distribuée sur plusieurs requêtes alors qu'une politique tenant compte de la frontière résiduelle la conserve ?
- **EQ3 – Coût système confirmatoire** : relativement à PERMISSIVE\_GATED, quels endpoints préspecifiés sont réduits par SAFE\_PRUNING sur SQL Server Direct ?
- **EQ4 – Break-even pratique** : les économies de travail backend suffisent-elles à rendre SAFE\_PRUNING plus rapide que UNGATED\_EXECUTE\_ADMISSIBLE dans la campagne contrôlée correspondante ?
- **EQ5 – Réplication backend** : quelles conclusions endpoint-spécifiques sont confirmées séparément sur SQL Direct et sur XMLA/eMondrian, et quelles comparaisons cross-backend restent non autorisées ?

Le Tableau IV synthétise la hiérarchie des campagnes et empêche de promouvoir un résultat descriptif ou historique au rang de confirmation inférentielle.

#### B. Évidence historique : fonctionnement, portée et limites

Les campagnes historiques restent utiles comme preuves de fonctionnement et de diversité de configuration. La trace AdventureWorks Q1–Q6 établit qu'une politique peut appliquer une décision avant backend ; la campagne FoodMart historique exerce 1000 sessions et 7960 décisions ; les campagnes multi-entrepôts et backend apparié montrent que des décisions et motifs peuvent être préservés dans plusieurs chemins exercés ; les benchmarks historiques de robustesse, de croissance structurelle et de latence sémantique caractérisent le prototype et certaines sensibilités internes.

Ces résultats ne sont toutefois pas réinterprétés comme preuve du nouveau prédicat d'élagage sûr. En particulier, les anciennes politiques strictes basées sur la contribution immédiate et les anciennes lectures en  $\Delta\varphi$  sont conservées comme contexte historique, mais elles ne définissent plus le

contrat normatif post-A8. De même, les quantiles historiques de latence sémantique n'incluaient pas nécessairement le coût complet du backend ; ils ne sont donc pas utilisés pour conclure sur le temps de bout en bout de R3.

#### C. NH-R2 : préservation et contribution différée multi-requêtes

NH-R2 exerce explicitement des scénarios où l'évidence utile à un support est répartie sur plusieurs requêtes. L'observation centrale est qu'une requête peut ne rendre immédiatement aucune nouvelle contrainte calculable tout en apportant une partie d'un support qui deviendra suffisant après une requête ultérieure. Une politique strictement immédiate peut donc supprimer une étape nécessaire à la complétion future.

Dans le périmètre gelé de NH-R2, la politique fondée sur la frontière résiduelle ne présente pas de violation observée de complétion, tandis que le baseline STRICT\_IMMEDIATE expose la perte de contributions différées dans les cas préspecifiés. Ce résultat soutient la distinction

$$\text{NONCONTRIBUTIVE\_NOW} \not\approx \text{SAFE\_TO\_PRUNE},$$

mais ne constitue ni une preuve universelle pour toute forme de session, ni une validation automatique de tout mapping d'évidence possible.

#### D. R3-C : exécution contrôlée et absence de break-even établie face à UNGATED

R3-C confronte la politique sûre à UNGATED\_EXECUTE\_ADMISSIBLE, qui exécute les requêtes admissibles sans rechercher de preuve d'élagage. Ce comparateur répond à une question différente de la comparaison confirmatoire primaire : il demande si le coût du contrôle pré-backend est amorti par les exécutions évitées dans les scénarios testés.

Dans les 40 sessions contrôlées de ce protocole, SAFE\_PRUNING est plus lent que UNGATED\_EXECUTE\_ADMISSIBLE pour le temps observé

TABLE IV  
ÉCHELLE D'ÉVIDENCE POST-A8 ET RÔLE PROBATOIRE DE CHAQUE CAMPAGNE.

| Niveau     | Campagne / comparateur                                                              | Ce que la campagne autorise                                                                                                                | Ce qu'elle n'autorise pas                                                                                                               |
|------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
| Historique | Q1–Q6, FoodMart, multi-entrepôts, parité backend, robustesse, scalabilité/latence   | Fonctionnement du prototype, variété de chemins, diagnostics et caractérisations descriptives                                              | Preuve confirmatoire du safe pruning post-A8, performance end-to-end universelle ou valeur décisionnelle humaine                        |
| NH-R2      | SAFE vs politique strictement immédiate dans des scénarios multi-requêtes contrôlés | Contribution différée, préservation de complétion dans le périmètre gelé, borne contre la règle “non contributif maintenant = dispensable” | Universalité sur toute session, tout objectif ou tout mapping d'évidence                                                                |
| R3-C       | SAFE_PRUNING vs UNGATED_EXECUTE_ADMISSIBLE                                          | Test pratique de break-even ; 40/40 sessions observées plus lentes sous SAFE dans ce protocole                                             | Claim que SAFE est universellement plus rapide que l'exécution admissible non instrumentée                                              |
| R3-D       | SAFE_PRUNING vs PERMISSIVE_GATED, SQL Server Direct                                 | Confirmation endpoint-spécifique sur 300 sessions / 900 bras, 8 endpoints primaires, correction de Holm                                    | Bénéfice système global indivisible, confirmation des I/O non significatives, réplication XMLA                                          |
| R3-E14     | SAFE_PRUNING vs PERMISSIVE_GATED, XMLA/eMondrian                                    | Réplication secondaire mesurée sur 300 sessions / 900 bras ; 8/8 endpoints primaires confirmés avec correction de Holm                     | Équivalence backend, homogénéité d'effet, synthèse cross-backend, bénéfice système global ou promotion confirmatoire de SAFE vs UNGATED |

de session, soit 40/40 cas dans le même sens. Le break-even temporel n'est donc pas établi dans ce périmètre. Cette observation n'annule pas les réductions de travail backend mesurées plus tard contre `PERMISSIVE_GATED` ; elle montre simplement que *moins de travail backend* et *temps de session inférieur à une exécution non instrumentée* sont deux claims distincts.

#### E. R3-D : campagne confirmatoire SQL Server Direct

R3-D constitue la campagne confirmatoire préspecifiée de coût système. Le plan comprend 300 sessions, soit 900 exécutions de bras au total, organisées en 20 strates de 15 sessions. La comparaison primaire est

`SAFE_PRUNING` – `PERMISSIVE_GATED`,

et les huit endpoints primaires sont orientés *lower-is-better*. Le test principal est un test de permutation apparié unilatéral par inversion de signes avec 100000 permutations ; les huit  $p$ -values sont corrigées par Holm pour contrôler la FWER à 0,05. Les intervalles descriptifs complémentaires utilisent un bootstrap percentile stratifié à 95% avec 20000 réplifications et une graine gelée par le protocole.

Les huit endpoints primaires et leur statut confirmatoire sont reportés dans le Tableau V.

Six endpoints sur huit sont confirmés en faveur de `SAFE_PRUNING`. La différence moyenne est de  $-16.2$  pour le nombre de requêtes backend incluant les probes, et de  $-16.2$  pour le nombre d'exécutions backend complètes. Le temps client diminue de 913.321858403 ms en moyenne, les octets de réponse de 150731.476667, le CPU SQL Server de 771626.43  $\mu$ s, et le temps jusqu'à complétion analytique de 202.580846887 ms. Pour ces six endpoints, le test apparié atteint la résolution minimale du protocole ( $p \approx 9.9999 \times 10^{-6}$ ) et la correction de Holm reste significative ( $p_{\text{Holm}} \approx 7.99992 \times 10^{-5}$ ).

Les deux endpoints d'I/O en octets ne sont pas confirmés. Les lectures SQL Server présentent une différence moyenne de  $-94126.08$  octets et les écritures de  $-2416.64$  octets, mais leur  $p_{\text{Holm}}$  vaut 0.429436. Ces directions descriptives ne sont donc pas promues en résultats confirmatoires.

La conclusion R3-D est volontairement endpoint-spécifique : le protocole autorise à dire que six endpoints primaires sur huit sont confirmés, mais n'autorise pas un claim indivisible du type “bénéfice système global”. De même, cette comparaison primaire n'implique pas que `SAFE_PRUNING` soit universellement plus rapide que `UNGATED_EXECUTE_ADMISSIBLE` ; R3-C fournit précisément une borne négative sur cette lecture.

#### F. R3-E14 : réplication secondaire XMLA/eMondrian mesurée

La voie XMLA/eMondrian a été exécutée comme une réplication R3 distincte après fermeture de la préparation et des barrières de runtime. La campagne R3-E14 comprend 300 sessions appariées et 900 bras. La comparaison primaire `SAFE_PRUNING` versus `PERMISSIVE_GATED` reprend les huit endpoints *lower-is-better* préspecifiés et la même correction de Holm. Les huit endpoints sont confirmés dans la direction favorable à `SAFE_PRUNING` ; pour chacun,  $p_{\text{Holm}} = 7.9999200008 \times 10^{-5}$ .

Cette réplication est interprétée endpoint par endpoint et comme rôle backend secondaire. Elle n'autorise ni équivalence des backends, ni homogénéité des effets, ni test de différence d'effet cross-backend, ni synthèse cross-backend, ni nouveau claim global de bénéfice système. La comparaison secondaire `SAFE_PRUNING` versus `UNGATED_EXECUTE_ADMISSIBLE` et les diagnostics de ressources spécifiques à XMLA restent descriptifs seulement.

#### G. Interprétation intégrée et frontières de claim

L'échelle d'évidence conduit à cinq conclusions bornées. Premièrement, les campagnes contrôlées soutiennent la nécessité de distinguer contribution immédiate et sûreté d'élague, notamment en présence de supports multi-requêtes. Deuxièmement, R3-D confirme des réductions de travail backend, de temps client, de CPU, d'octets de réponse et de temps jusqu'à complétion analytique relativement à `PERMISSIVE_GATED`. Troisièmement, les I/O SQL Server en octets restent non confirmées et aucun bénéfice système global indivisible n'est autorisé. Quatrièmement, R3-E14 confirme séparément 8/8 endpoints primaires sur XMLA/eMondrian relativement à `PERMISSIVE_GATED`, sans transformer cette réplication

TABLE V

R3-D : ENDPOINTS PRIMAIRES PRÉSPÉCIFIÉS POUR SAFE\_PRUNING — PERMISSIVE\_GATED. LES HUIT ENDPOINTS SONT *lower-is-better* ; UNE DIFFÉRENCE NÉGATIVE FAVORISE SAFE.

| Endpoint primaire                        | Différence moyenne | $p_{Holm}$                       | Statut       |
|------------------------------------------|--------------------|----------------------------------|--------------|
| Requêtes backend, probes inclus          | -16.2              | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| Exécutions backend complètes             | -16.2              | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| Temps client (ms)                        | -913.321858403     | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| Octets de réponse                        | -150731.476667     | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| CPU SQL Server ( $\mu s$ )               | -771626.43         | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| Temps jusqu'à complétion analytique (ms) | -202.580846887     | $\approx 7.99992 \times 10^{-5}$ | Confirmé     |
| Lectures I/O SQL Server (octets)         | -94126.08          | 0.429436                         | Non confirmé |
| Écritures I/O SQL Server (octets)        | -2416.64           | 0.429436                         | Non confirmé |

TABLE VI

R3-E14 XMLA/EMONDRIAN : ENDPOINTS PRIMAIRES DE LA COMPARAISON SAFE\_PRUNING — PERMISSIVE\_GATED. LES HUIT ENDPOINTS SONT PRÉSPÉCIFIÉS *lower-is-better* ; LES VALEURS SONT LES DIFFÉRENCES MOYENNES GELÉES ET LES  $p$  AJUSTÉS DE HOLM.

| Endpoint primaire                        | Différence moyenne | $p_{Holm}$       | Statut   |
|------------------------------------------|--------------------|------------------|----------|
| Exécutions backend complètes             | -16.2              | 7.9999200008e-05 | Confirmé |
| Requêtes backend, probes inclus          | -16.2              | 7.9999200008e-05 | Confirmé |
| Temps client (ms)                        | -2493.66708613     | 7.9999200008e-05 | Confirmé |
| CPU SQL Server ( $\mu s$ )               | -2057148.76        | 7.9999200008e-05 | Confirmé |
| Lectures I/O SQL Server (octets)         | -237158.4          | 7.9999200008e-05 | Confirmé |
| Écritures I/O SQL Server (octets)        | -530005.333333     | 7.9999200008e-05 | Confirmé |
| Octets de réponse                        | -584672.966667     | 7.9999200008e-05 | Confirmé |
| Temps jusqu'à complétion analytique (ms) | -520.288297013     | 7.9999200008e-05 | Confirmé |

en équivalence inter-backend. Cinquièmement, le break-even temporel face à UNGATED\_EXECUTE\_ADMISSIBLE n'est pas établi par R3-C et la comparaison XMLA SAFE versus UNGATED reste descriptive.

Ces résultats portent sur la complétion analytique et le coût système du contrôle. Ils ne mesurent ni la qualité d'une décision humaine, ni la satisfaction d'un analyste, ni un avantage organisationnel final. Ils n'établissent pas non plus une supériorité universelle sur des systèmes externes, une scalabilité industrielle sous concurrence, ou la validité automatique de CKG, objectifs et mappings construits hors du protocole.

*Traçabilité probatoire.* : Les claims post-A8 sont liés aux campagnes qui les autorisent : NH-R2 pour la contribution différée et la préservation contrôlée ; R3-C pour le break-even pratique face à UNGATED ; R3-D pour la confirmation SQL Direct endpoint par endpoint ; R3-E14 pour la réplification secondaire XMLA endpoint par endpoint. Cette séparation empêche de combiner des niveaux de preuve hétérogènes en une conclusion plus forte que leurs protocoles respectifs et n'autorise aucune synthèse cross-backend.

## VII. DISCUSSION, LIMITES ET PERSPECTIVES

Le résultat central de cette étude n'est pas qu'une requête "sans contribution immédiate" doive être supprimée. Il est au contraire que la décision d'élagage doit être séparée de la simple contribution marginale et formulée relativement à ce qui reste nécessaire pour compléter l'objectif. Le contrat post-A8 peut ainsi se résumer par deux relations complémentaires :

$$\text{NONCONTRIBUTIVE\_NOW} \not\equiv \text{SAFE\_TO\_PRUNE},$$

et, sous les hypothèses gelées du modèle,

$$N_E(q) \cap U(\mathcal{E}_t) = \emptyset$$

comme condition suffisante et conservatrice permettant d'autoriser l'élagage. Cette formulation déplace le centre de gravité de MCAD : le système n'est plus présenté comme un classifieur universel de "bonnes" et "mauvaises" requêtes, mais comme un contrôle objectif-relatif qui cherche à préserver la complétion analytique tout en évitant certaines exécutions devenues dispensables.

### A. Sémantique, politique et coût système sont trois objets distincts

Le premier enseignement est méthodologique. L'admissibilité sémantique, la réalisabilité d'une évidence, l'évidence effectivement acquise, la calculabilité d'une contrainte et l'action opérationnelle doivent rester distinctes. Un probe peut établir une propriété de réalisabilité sans créditer l'état de session ; une exécution complète réussie peut enrichir  $\mathcal{E}_t$  ; une politique peut enfin transformer la preuve disponible en PRUNE, EXECUTE, avertissement ou guidage. En cas d'incertitude de canonicalisation, de mapping ou de preuve, le mécanisme retourne vers l'exécution *fail-open* plutôt que de créer un faux élagage.

Cette séparation permet également d'interpréter correctement les comparateurs. PERMISSIVE\_GATED est le comparateur causal primaire de R3-D pour isoler l'effet du safe pruning à instrumentation comparable. UNGATED\_EXECUTE\_ADMISSIBLE répond à une question pratique différente : le coût du contrôle est-il amorti face à une exécution admissible non filtrée ? Enfin, STRICT\_IMMEDIATE reste utile comme baseline sémantique pour exposer la perte de contribution différée. Aucun de ces modes ne redéfinit le noyau sémantique.

*B. Ce que les résultats système établissent – et ce qu’ils n’établissent pas*

R3-D fournit une évidence confirmatoire endpoint-spécifique. Six des huit endpoints primaires préspecifiés sont confirmés en faveur de `SAFE_PRUNING` relativement à `PERMISSIVE_GATED` : requêtes backend incluant les probes, exécutions backend complètes, temps client, CPU SQL Server, octets de réponse et temps jusqu’à complétion analytique. Les lectures et écritures I/O SQL Server en octets ne sont pas confirmées ( $p_{\text{Holm}} = 0.429436$  pour les deux endpoints). Ils n’établissent donc aucun bénéfice système global indivisible.

R3-C fournit une borne complémentaire : dans les 40/40 sessions contrôlées de ce protocole, `SAFE_PRUNING` est plus lent que `UNGATED_EXECUTE_ADMISSIBLE`. Le break-even temporel face à `UNGATED` n’est donc pas établi. Ces deux résultats ne sont pas contradictoires : réduire le travail backend relativement à un comparateur instrumenté et battre en temps mur une exécution admissible non contrôlée sont deux hypothèses différentes. L’article maintient volontairement cette dissociation plutôt que de choisir seulement le résultat favorable.

*C. Contribution différée et portée de la preuve de sûreté*

NH-R2 montre pourquoi l’état de session ne peut pas être réduit à la dernière requête exécutée. Une requête peut fournir une partie d’un support sans rendre immédiatement une nouvelle contrainte calculable ; une requête ultérieure complète alors le support. Une politique strictement immédiate peut perdre cette contribution différée. La frontière résiduelle  $U(\mathcal{E}_t)$  évite ce raccourci en conservant les atomes encore nécessaires à l’ensemble des supports actifs.

La condition d’élagage utilisée ici demeure toutefois une condition suffisante, non une caractérisation nécessaire de toute dispensabilité possible. Elle dépend notamment de la fidélité du CQP, de la sûreté de  $N_E(q)$  comme sur-approximation de l’évidence pertinente, du caractère correct des mappings d’évidence et du gel des objectifs/supports pendant la phase considérée. Si ces hypothèses sont violées ou inconnues, la conclusion correcte est “preuve insuffisante” et non “requête dispensable”.

*D. Validité du construit et dépendance à la spécification objectif–évidence*

MCAD raisonne relativement à un objectif  $O$ , à un graphe objectif–évidence  $G_O$  et à des supports suffisants fournis au système. La cohérence du raisonneur relativement à ces objets ne valide pas automatiquement leur pertinence métier. Une contrainte mal formulée, un support incomplet ou un mapping d’évidence erroné peut conduire à un raisonnement cohérent sur une spécification inadéquate. L’étude distingue donc : (i) la correction du raisonnement sous la spécification encodée ; (ii) la justesse de cette spécification relativement au besoin métier ; et (iii) la valeur de la décision humaine produite à partir des résultats. Seul le premier niveau est directement testé par le mécanisme, avec des campagnes contrôlées qui exercent certaines propriétés du deuxième sans l’établir indépendamment.

La construction automatique du CKG, de  $G_O$ , des supports suffisants et des mappings d’évidence n’est pas évaluée. Les campagnes utilisent des objets préparés et audités pour le protocole. L’automatisation de cette construction, sa maintenance face à l’évolution du schéma et l’accord entre experts constituent donc des travaux futurs plutôt que des résultats implicites de MCAD.

*E. Validité externe, backends et changement d’échelle*

La confirmation R3-D porte sur SQL Server Direct. Les expériences historiques montrent que le prototype avait déjà exercé des chemins XMLA/Mondrian et plusieurs entrepôts ; R3-E14 ajoute désormais une réplication secondaire mesurée sur XMLA/eMondrian, avec 8/8 endpoints primaires confirmés pour `SAFE_PRUNING` versus `PERMISSIVE_GATED`. Ce résultat ne constitue cependant ni une preuve d’équivalence des backends, ni une homogénéité des effets, ni un test direct de différence d’effet entre SQL Direct et XMLA.

Le protocole courant n’établit pas non plus une scalabilité industrielle sous concurrence. Débit multi-utilisateur, files d’attente, mémoire, contention, changements de charge, maintenance dynamique du CKG et grands portefeuilles d’objectifs restent à caractériser de bout en bout. Les anciennes mesures de croissance structurelle et de latence sémantique restent informatives sur le prototype historique mais ne se substituent pas à ces expériences système.

*F. Portabilité de représentation et extension à d’autres langages*

Le CQP découple le raisonneur de la syntaxe source lorsque l’extracteur est fidèle. SQL analytique et MDX/XMLA disposent de chemins exercés vers cette représentation. Cette propriété est une portabilité bornée d’interface, non une preuve que tous les langages ou moteurs exposent la même sémantique ni qu’un adaptateur est automatiquement correct. DAX reste notamment une extension future à implémenter, auditer et tester avant toute revendication de portabilité supplémentaire.

*G. Facteurs humains et politique de déploiement*

Le temps jusqu’à complétion analytique mesure l’atteinte de l’objectif formel du protocole, pas la qualité d’une décision organisationnelle. L’étude ne mesure ni satisfaction, ni apprentissage, ni confiance, ni amélioration économique, et ne permet pas de conclure qu’un PRUNE sûr du point de vue de la complétion est préférable pour un analyste dans toutes les situations. Des études utilisateurs restent nécessaires pour comparer exécution silencieuse, notification, avertissement, guidage et recommandation lorsque plusieurs actions sont sémantiquement admissibles.

De même, l’article ne revendique ni supériorité universelle sur les systèmes voisins, ni claim de priorité “first/only”. Le positionnement scientifique porte sur l’intégration contrôlée de l’objectif, de l’évidence de session, du CQP, de la frontière résiduelle et d’une preuve d’élagage sûr, dans les limites empiriques explicitement exercées.

## H. Perspectives

Les priorités expérimentales et méthodologiques suivent directement les frontières précédentes : (i) mesurer concurrence, mémoire, files d'attente et changement d'échelle end-to-end ; (ii) étudier la construction et la validation indépendantes de CKG/ $G_O$ /supports/mappings ; (iii) étendre puis auditer le contrat CQP pour DAX et d'autres langages ; (iv) confronter plusieurs politiques d'interaction dans des études utilisateurs ; et (v) étudier des conditions de sûreté moins conservatrices tout en préservant le comportement *fail-open* lorsque la preuve devient insuffisante.

## VIII. CONCLUSION

MCAD est présenté dans cette version comme une couche de contrôle analytique objectif-relative placée avant l'exécution complète. Un objectif  $O$  est décomposé en contraintes, supports suffisants et atomes d'évidence dans  $G_O$  ; la requête candidate est projetée vers un *Canonical Query Profile* ; le raisonneur sépare admissibilité, réalisabilité et évidence acquise ; puis une preuve de sûreté confronte  $N_E(q)$  à la frontière résiduelle  $U(\mathcal{E}_t)$ . Une requête n'est élaguée que lorsque sa dispensabilité est établie sous les hypothèses gelées ; sinon, MCAD exécute en *fail-open*. Un probe réussi ne vaut pas acquisition d'évidence, et PRUNE laisse l'état acquis inchangé.

Les campagnes contrôlées montrent l'importance de cette distinction dans les sessions multi-requêtes : NH-R2 exerce des contributions différées que la règle strictement immédiate peut perdre. La campagne confirmatoire SQL Server Direct R3-D compare `SAFE_PRUNING` à `PERMISSIVE_GATED` sur huit endpoints primaires ; six sont confirmés en faveur de `SAFE`, tandis que les lectures et écritures I/O en octets ne le sont pas. R3-C montre en parallèle que le break-even temporel face à `UNGATED_EXECUTE_ADMISSIBLE` n'est pas établi. Ces résultats autorisent donc des claims endpoint-spécifiques, pas un bénéfice système global indivisible ni une supériorité universelle.

La réplication secondaire XMLA/eMondrian R3-E14 confirme 8/8 endpoints primaires relativement à `PERMISSIVE_GATED`, tandis que R3-D en confirme 6/8 sur SQL Direct ; ces résultats restent séparés et n'établissent ni équivalence backend, ni homogénéité d'effet, ni bénéfice système global. La qualité de la décision humaine, la construction automatique des objectifs et graphes d'évidence, la concurrence industrielle et la portabilité vers DAX restent également hors du périmètre confirmé. Dans ces limites, MCAD fournit un mécanisme explicable de préservation de la complétion analytique et d'élagage sûr relatif à l'objectif, dont les bénéfices et coûts doivent être interprétés séparément selon le backend, la politique et l'endpoint considérés.

## ANNEXE A

### PREUVES FORMELLES COMPLÉMENTAIRES POST-A8

Cette annexe développe les propriétés utilisées par le noyau formel post-A8 sans réintroduire les objets et relations abandonnés de la formalisation antérieure. Les hypothèses sont celles de la Section IV : objectif  $O$ , graphe objectif-évidence  $G_O$ , supports suffisants gelés pendant la phase considérée,

évidence acquise  $\mathcal{E}_t$ , CQP fidèle ou traitement *fail-open*, et sur-approximation sûre  $N_E(q)$  de l'évidence pertinente que l'exécution complète de  $q$  pourrait acquérir.

*Lemme 1 – Monotonie de la calculabilité sous accumulation d'évidence.* : Supposons  $\mathcal{E}_{t-1} \subseteq \mathcal{E}_t$ . Pour toute contrainte  $c \in O$ , si  $\text{Comp}(c, \mathcal{E}_{t-1})$  est vraie, alors il existe, par l'Éq. (1), un support  $s \in \text{Supp}(c)$  tel que  $\text{Req}(s) \subseteq \mathcal{E}_{t-1}$ . L'inclusion  $\mathcal{E}_{t-1} \subseteq \mathcal{E}_t$  implique alors  $\text{Req}(s) \subseteq \mathcal{E}_t$ , donc  $\text{Comp}(c, \mathcal{E}_t)$ . Par conséquent,

$$C_{\mathcal{E}}^{\leq t-1}(O) \subseteq C_{\mathcal{E}}^{\leq t}(O).$$

Cette propriété ne requiert aucune hypothèse sur la requête qui a produit l'évidence, seulement la conservation monotone de l'évidence acquise dans la phase. ■

*Lemme 2 – Un probe seul ne peut pas faire progresser la calculabilité acquise.* : Un probe de réalisabilité peut établir  $R_E(q) \subseteq N_E(q)$ , mais il ne produit pas d'ensemble d'évidence acquise  $A_t$ . Ainsi  $A_t = \emptyset$  et l'Éq. (4) donne

$$\mathcal{E}_t = \mathcal{E}_{t-1}.$$

Le Lemme 1 implique alors

$$C_{\mathcal{E}}^{\leq t}(O) = C_{\mathcal{E}}^{\leq t-1}(O).$$

Le coût du probe peut être attribué à la session, mais son succès ne doit donc jamais être interprété comme l'acquisition du résultat analytique. ■

*Preuve détaillée de la Proposition 1.* : Considérons une requête candidate  $q$  à l'état  $\mathcal{E}_t$  et supposons

$$N_E(q) \cap U(\mathcal{E}_t) = \emptyset.$$

Soit  $A(q) \subseteq N_E(q)$  l'ensemble d'évidence qui serait effectivement acquis si  $q$  était exécutée complètement avec succès. Pour toute contrainte active  $c \in C_t^{\text{act}}$  et tout support  $s \in \text{Supp}(c)$ , les atomes encore manquants sont

$$M_s = \text{Req}(s) \setminus \mathcal{E}_t.$$

Par définition de la frontière résiduelle à l'Éq. (2),  $M_s \subseteq U(\mathcal{E}_t)$ . L'hypothèse de disjonction implique donc

$$A(q) \cap M_s = \emptyset.$$

Après exécution hypothétique, l'état serait  $\mathcal{E}' = \mathcal{E}_t \cup A(q)$ . On a alors

$$\text{Req}(s) \setminus \mathcal{E}' = \text{Req}(s) \setminus \mathcal{E}_t = M_s.$$

Aucun support actif ne gagne donc un atome qui lui manquait. Une contrainte déjà calculable reste calculable par monotonie, et aucune contrainte active ne devient calculable par l'effet de  $q$ . L'exécution complète de  $q$  ne modifie ainsi ni la complétion déjà acquise ni la progression des supports actifs relativement à  $O$  ; l'élagage préserve la complétion analytique sous les hypothèses gelées. ■

*Corollaire – Préservation immédiate après PRUNE.* :

Lorsque la politique retourne PRUNE, l'Éq. (5) impose  $A_t = \emptyset$  puis  $\mathcal{E}_t = \mathcal{E}_{t-1}$ . Par application directe de l'Éq. (1), l'ensemble des contraintes calculables reste donc exactement inchangé. Ce corollaire concerne l'état d'évidence ; il n'implique pas un coût backend nul si un probe précédé la décision. ■

*Contre-exemple à la règle “non contributif maintenant  $\Rightarrow$  élagable”.*: Considérons une contrainte  $c$  ayant un support unique  $s$  tel que

$$\text{Req}(s) = \{e_1, e_2\}, \quad \mathcal{E}_0 = \emptyset.$$

Une première requête  $q_1$  peut acquérir  $A_1 = \{e_1\}$  et une seconde  $q_2$  peut acquérir  $A_2 = \{e_2\}$ . Après  $q_1$ , aucune contrainte nouvelle n’est encore calculable, mais  $N_E(q_1)$  intersecte la frontière  $U(\mathcal{E}_0) = \{e_1, e_2\}$ . La condition suffisante d’élagage sûr échoue donc, ce qui conduit à l’exécution *fail-open*. Après l’acquisition de  $e_1$ ,  $q_2$  complète le support et rend  $c$  calculable. Cet exemple formalise le mécanisme de contribution différée exercé dans NH-R2 et montre pourquoi

NONCONTRIBUTIVE\_NOW  $\not\equiv$  SAFE\_TO\_PRUNE.

*Portée des preuves.*: Ces résultats sont relatifs à la spécification encodée. Ils supposent en particulier que les supports suffisants et les mappings d’évidence sont corrects, que  $N_E(q)$  constitue une sur-approximation sûre de l’évidence pertinente et que la phase n’altère pas silencieusement l’objectif ou ses supports. Si ces hypothèses ne peuvent pas être établies, la conclusion opérationnelle est l’exécution *fail-open*, non l’élagage.

## ANNEXE B

### EXEMPLE FOODMART HF/NORTH REFORMULÉ DANS LE CONTRAT POST-A8

Cette annexe conserve l’exemple FoodMart historique comme illustration formelle, mais le reformule avec le graphe objectif-évidence, le CQP et l’évidence acquise du modèle post-A8. Elle ne réinterprète aucune campagne expérimentale historique comme preuve confirmatoire de SAFE\_PRUNING.

Le cube *Sales* comporte notamment les dimensions *Time*, *Product* et *Store*, les mesures *Store Sales*, *Store Cost* et *Units Sold*, ainsi qu’un KPI dérivé de marge. Nous considérons l’objectif illustratif

$$O_{\text{HF\_North}} = \{c_1, c_2, c_3\},$$

relatif à la catégorie Health Food, à la région North et aux fenêtres temporelles utilisées dans l’exemple historique.

*Graphe objectif-évidence.*: Le graphe  $G_{O_{\text{HF\_North}}}$  contient trois contraintes, leurs supports suffisants et des atomes d’évidence typés. Pour  $c_1$ , un support illustratif  $s_1$  exige les douze valeurs mensuelles du KPI de marge pour 1998 :

$$\text{Req}(s_1) = \{e_{1,1}, \dots, e_{1,12}\}.$$

Chaque  $e_{1,m}$  encode la source *Sales*, le grain *Month*, la catégorie Health Food, la région North, le KPI de marge, son agrégation, son unité et le mois concerné. De façon analogue,  $c_2$  est reliée à un support  $s_2$  portant sur l’évidence de taux de rupture au grain *Store*, et  $c_3$  à un support  $s_3$  portant sur l’évidence de ventes agrégées sur la fenêtre 1997–1998. L’exemple n’impose pas qu’une contrainte n’ait qu’un seul support : d’autres supports suffisants peuvent être ajoutés au graphe si la spécification métier l’autorise.

La calculabilité suit directement l’Éq. (1). Ainsi,

$$\text{Comp}(c_1, \mathcal{E}_t) \iff \text{Req}(s_1) \subseteq \mathcal{E}_t$$

dans la variante illustrative à support unique pour  $c_1$ .

*Canonical Query Profile (CQP) d’une requête de marge.*: Soit  $q_1$  une requête analytique demandant la marge mensuelle de Health Food dans North pour 1998. Son profil canonique peut être résumé par

$$\begin{aligned} P_{q_1} &= \text{CQP}(q_1) \\ &= (\text{Sales}, \text{Month}, \{\text{Margin}\% \}, \text{avg}, \%, \\ &\quad S_{\text{HF}, \text{North}}, w_{1998}, \Gamma_{q_1}, \eta_{q_1}). \end{aligned}$$

Si le mapping est fidèle,

$$N_E(q_1) \supseteq \{e_{1,1}, \dots, e_{1,12}\}.$$

L’admissibilité de  $P_{q_1}$  vérifie les propriétés de grain, agrégation, unité, slicers, temps et mapping. Une éventuelle vérification de non-vacuité reste un probe de réalisabilité séparé et ne modifie pas  $\mathcal{E}_t$ .

*Acquisition complète d’un support.*: Si  $q_1$  est exécutée complètement avec succès et que son résultat fournit les douze atomes du support, alors

$$A_1 \supseteq \text{Req}(s_1), \quad \mathcal{E}_1 = \mathcal{E}_0 \cup A_1,$$

et  $c_1$  devient calculable. La même logique s’applique aux supports de  $c_2$  et  $c_3$  : la calculabilité dépend de l’évidence effectivement acquise, pas de la seule description potentielle de la requête.

*Contribution différée intra-support.*: Pour illustrer le cas multi-requêtes, divisons le support  $s_1$  en deux acquisitions successives. La requête  $q_{1a}$  couvre les six premiers mois et  $q_{1b}$  les six derniers :

$$A_{1a} = \{e_{1,1}, \dots, e_{1,6}\}, \quad A_{1b} = \{e_{1,7}, \dots, e_{1,12}\}.$$

Avec  $\mathcal{E}_0 = \emptyset$ , l’exécution de  $q_{1a}$  ne rend pas encore  $c_1$  calculable. Elle est néanmoins contributive au support résiduel car

$$N_E(q_{1a}) \cap U(\mathcal{E}_0) \neq \emptyset.$$

Après cette première acquisition,

$$\mathcal{E}_1 = A_{1a},$$

puis  $q_{1b}$  complète  $s_1$  et rend  $c_1$  calculable. Une politique qui élaguerait  $q_{1a}$  uniquement parce qu’elle ne complète aucune contrainte immédiatement perdrait donc la contribution différée.

*Exemple d’élagage sûr relatif à l’objectif.*: Considérons maintenant une requête  $q_x$  dont le CQP fidèle ne mappe que vers des atomes d’évidence extérieurs aux supports encore actifs de  $O_{\text{HF\_North}}$ . Si

$$N_E(q_x) \cap U(\mathcal{E}_t) = \emptyset,$$

alors la Proposition 1 autorise l’élagage sous les hypothèses gelées. L’exemple est relatif à l’objectif : la même requête pourrait redevenir pertinente dans une autre session, pour un autre objectif ou après modification explicite des supports.

*Limite de l’illustration.*: Le présent exemple démontre la cohérence du raisonnement sur une spécification contrôlée. Il n’établit ni la construction automatique correcte de  $G_O$ , ni la validité métier indépendante des supports choisis, ni un résultat de performance XMLA/eMondrian pour ce scénario illustratif. Les campagnes historiques FoodMart restent des preuves de fonctionnement du prototype ; la réplication secondaire R3-E14 est désormais mesurée séparément dans son protocole XMLA/eMondrian et ne doit pas être attribuée à cette illustration FoodMart.



# RÉFÉRENCES

- [1] S. Chaudhuri and U. Dayal, “An overview of data warehousing and OLAP technology,” *ACM SIGMOD Record*, vol. 26, no. 1, pp. 65–74, 1997, doi : 10.1145/248603.248616.
- [2] R. Kimball and M. Ross, *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*, 3rd ed. Hoboken, NJ, USA : Wiley, 2013.
- [3] H. Chen, R. H. L. Chiang, and V. C. Storey, “Business intelligence and analytics : From big data to big impact,” *MIS Quarterly*, vol. 36, no. 4, pp. 1165–1188, 2012, doi : 10.2307/41703503.
- [4] M. Golfarelli, S. Rizzi, and P. Biondi, “myOLAP : An approach to express and evaluate OLAP preferences,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 23, no. 7, pp. 1050–1064, 2011, doi : 10.1109/TKDE.2010.196.
- [5] K. Jacob, J. Gunklach, and A. Mädche, “Personalization in business intelligence and analytics systems : A state-of-the-art review and conceptualization,” in *ECIS 2025 Proceedings*, 2025.
- [6] J. Aligon, E. Gallinucci, M. Golfarelli, P. Marcel, and S. Rizzi, “A collaborative filtering approach for recommending OLAP sessions,” *Decision Support Systems*, vol. 69, pp. 20–30, 2015, doi : 10.1016/j.dss.2014.11.003.
- [7] J. Gunklach and M. Nadj, “Guidance in business intelligence & analytics systems : A review and research agenda,” in *ECIS 2023 Research Papers*, 2023.
- [8] M. Djedaini, K. Drushku, N. Labroche, P. Marcel, V. Peralta, and W. Verdeaux, “Automatic assessment of interactive OLAP explorations,” *Information Systems*, vol. 82, pp. 148–163, 2019, doi : 10.1016/j.is.2018.06.008.
- [9] D. Gkitsakis, S. Kaloudis, E. Mouselli, V. Peralta, P. Marcel, and P. Vassiliadis, “Cube query interestingness : Novelty, relevance, peculiarity and surprise,” *Information Systems*, vol. 123, 2024, art. no. 102381. doi : 10.1016/j.is.2024.102381.
- [10] P. Vassiliadis, P. Marcel, and S. Rizzi, “Beyond roll-ups and drill-downs : An intentional analytics model to reinvent OLAP,” *Information Systems*, vol. 85, pp. 68–91, 2019, doi : 10.1016/j.is.2019.03.011.
- [11] A. Pourshahid, I. Johari, G. Richards, D. Amyot, and O. Akhigbe, “A goal-oriented, business intelligence-supported decision-making methodology,” *Decision Analytics*, vol. 1, 2014, art. no. 9. doi : 10.1186/s40165-014-0009-8.
- [12] A. Maté, J. Trujillo, and J. Mylopoulos, “Specification and derivation of key performance indicators for business analytics : A semantic approach,” *Data & Knowledge Engineering*, vol. 108, pp. 30–49, 2017, doi : 10.1016/j.datak.2016.12.004.
- [13] A. Hogan *et al.*, “Knowledge graphs,” *ACM Computing Surveys*, vol. 54, no. 4, pp. 1–37, 2021, doi : 10.1145/3447772.
- [14] A. Nasiri, W. Ahmed, R. Wrembel, and E. Zimányi, “Requirements engineering for data warehouses (RE4DW) : From strategic goals to multidimensional model,” in *Advances in Conceptual Modeling – ER 2017 Workshops*, ser. Lecture Notes in Computer Science, vol. 10651. Cham, Switzerland : Springer, 2017, pp. 133–143, doi : 10.1007/978-3-319-70625-2\_13.
- [15] M. d. M. Roldán-García, J. García-Nieto, A. Maté, J. Trujillo, and J. F. Aldana-Montes, “Ontology-driven approach for KPI meta-modelling, selection and reasoning,” *International Journal of Information Management*, vol. 58, 2021, art. no. 102018. doi : 10.1016/j.ijinfomgt.2019.10.003.
- [16] C. Diamantini, T. Khan, D. Potena, and E. Storti, “Semantic models of performance indicators : A systematic survey,” *ACM Computing Surveys*, vol. 57, no. 8, pp. 1–37, 2025, doi : 10.1145/3719291.
- [17] L. Etcheverry, A. Vaisman, and E. Zimányi, “Modeling and querying data warehouses on the semantic web using QB4OLAP,” in *Data Warehousing and Knowledge Discovery*, ser. Lecture Notes in Computer Science, vol. 8646. Cham, Switzerland : Springer, 2014, pp. 45–56, doi : 10.1007/978-3-319-10160-6\_5.
- [18] W3C, “The RDF data cube vocabulary,” 2014, W3C Recommendation. [Online]. Available : <https://www.w3.org/TR/vocab-data-cube/>
- [19] C. G. Schuetz, L. Bozzato, B. Neumayr, M. Schrefl, and L. Serafini, “Knowledge graph OLAP : A multidimensional model and query operations for contextualized knowledge graphs,” *Semantic Web*, vol. 12, no. 4, pp. 649–683, 2021, doi : 10.3233/SW-200419.
- [20] J. Horner, I.-Y. Song, and P. P. Chen, “An analysis of additivity in OLAP systems,” in *Proceedings of the 7th ACM International Workshop on Data Warehousing and OLAP (DOLAP)*, 2004, pp. 83–91, doi : 10.1145/1031763.1031779.
- [21] E. Simon, B. Amann, R. Liu, and S. Gançarski, “Controlling the correctness of aggregation operations during sessions of interactive analytic queries,” *ACM Journal of Data and Information Quality*, vol. 15, no. 2, pp. 12 :1–12 :41, 2023, art. no. 12. doi : 10.1145/3575812.
- [22] O. AIOmeir, E. Y. Lai, M. Milani, and R. Pottinger, “Summarizing provenance of aggregate query results in relational databases,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 10, pp. 10 695–10 709, 2023, doi : 10.1109/TKDE.2023.3265840.
- [23] W3C, “PROV-O : The PROV ontology,” 2013, W3C Recommendation. [Online]. Available : <https://www.w3.org/TR/prov-o/>
- [24] S. Staudinger, C. G. Schuetz, M. Schrefl, and T. Neuböck, “Knowledge graph support for descriptive business analytics,” *DECISION*, vol. 52, no. 3, pp. 285–306, 2025, doi : 10.1007/s40622-025-00432-4.
- [25] G.-L. Huang and A. Zaslavsky, “Contextual knowledge graph approach to bias-reduced decision support systems,” *Journal of Decision Systems*, vol. 33, no. sup1, pp. 29–46, 2024.
- [26] E. Begoli, J. Camacho-Rodríguez, J. Hyde, M. J. Mior, and D. Lemire, “Apache calcite : A foundational framework for optimized query processing over heterogeneous data sources,” in *Proceedings of the 2018 International Conference on Management of Data*. ACM, 2018, pp. 221–230.
- [27] Substrait Community, “Substrait : Cross-language serialization for relational algebra — specification,” Online specification, 2026, accessed 2026-08-27. [Online]. Available : <https://substrait.io/spec/specification/>
- [28] M. Francia, M. Golfarelli, P. Marcel, S. Rizzi, and P. Vassiliadis, “Assess queries for interactive analysis of data cubes,” in *Proceedings of the 24th International Conference on Extending Database Technology (EDBT)*. OpenProceedings.org, 2021, pp. 121–132, doi : 10.5441/002/edbt.2021.12.
- [29] M. Francia, S. Rizzi, M. Golfarelli, and P. Marcel, “Predicting multidimensional cubes through intentional analytics,” *Information Systems*, vol. 136, 2026, art. no. 102628. doi : 10.1016/j.is.2025.102628.
- [30] M. Iakovidis and P. Vassiliadis, “Multi-query optimization for the novel analyze operator,” in *Proceedings of the 28th International Workshop on Design, Optimization, Languages and Analytical Processing of Big Data (DOLAP 2026)*, ser. CEUR Workshop Proceedings, vol. 4186, 2026, pp. 65–79. [Online]. Available : <https://ceur-ws.org/Vol-4186/paper5.pdf>
- [31] E. Bertino and D. Musto, “Query optimization by using knowledge about data semantics,” *Data & Knowledge Engineering*, vol. 9, no. 2, pp. 121–155, 1992.
- [32] J. Kossmann, T. Papenbrock, and F. Naumann, “Data dependencies for query optimization : a survey,” *The VLDB Journal*, vol. 31, no. 1, pp. 1–22, 2022.
- [33] G. Luo, “Efficient detection of empty-result queries,” in *Proceedings of the 32nd International Conference on Very Large Data Bases (VLDB)*, 2006, pp. 1015–1025.
- [34] S. Kraft, G. Casale, A. Julia, P. Kilpatrick, and D. Greer, “Wiq : Work-intensive query scheduling for in-memory database systems,” in *2012 IEEE 5th International Conference on Cloud Computing*, 2012, pp. 33–40.
- [35] S. Krompass, U. Dayal, H. A. Kuno, and A. Kemper, “Dynamic workload management for very large data warehouses : Juggling feathers and bowling balls,” in *Proceedings of the 33rd International Conference on Very Large Data Bases (VLDB 2007)*, 2007, pp. 1105–1115.
- [36] W. Powley, P. Martin, N. Gruska, P. Bird, and D. Kalmuk, “Resource aware workload management for autonomic database management systems,” in *Proceedings of the Tenth International Conference on Autonomic and Autonomous Systems (ICAS 2014)*, 2014, pp. 31–36.
- [37] Y. Wu, Y. Li, Z. Wang, Z. Xie, D. Yang, K. Chen, L. Shou, B. Tang, L. Lin, H. Li, and G. Chen, “Safeload : Efficient admission control framework for identifying memory-overloading queries in cloud data warehouses,” *Proceedings of the VLDB Endowment*, vol. 19, no. 4, pp. 713–725, 2025, pVLDB bibliographic year 2025 ; presented in the VLDB 2026 conference cycle.
- [38] X. Niu, Z. Liu, P. Li, B. Glavic, D. Gawlick, V. Krishnaswamy, Z. H. Liu, and D. Porobic, “Provenance-based data skipping,” *Proceedings of the VLDB Endowment*, vol. 15, no. 3, pp. 451–464, 2021.
- [39] U. Sadana, A. Chenreddy, E. Delage, A. Forel, E. Frejinger, and T. Vidal, “A survey of contextual optimization methods for decision-making under uncertainty,” *European Journal of Operational Research*, vol. 320, no. 2, pp. 271–289, 2025, doi : 10.1016/j.ejor.2024.03.020.